



DEPARTAMENTO DE CIÊNCIAS E TECNOLOGIAS
MESTRADO EM ENGENHARIA INFORMÁTICA E DE TELECOMUNICAÇÕES
UNIVERSIDADE AUTÓNOMA DE LISBOA
“LUÍS DE CAMÕES”

APRENDIZAGEM AUTOMÁTICA PARA APOIO A REVISÃO
SISTEMÁTICA DE LITERATURA

Dissertação para a obtenção do grau de Mestre em Engenharia Informática e de
Telecomunicações

Autor: Michael Dionísio Borges

Orientador: Professor Doutor Gonçalo Ramiro Valadão Matias

Número do candidato: 30001171

Julho de 2020

Lisboa

Dedicatória

Dedico este trabalho ao meu pai, *Allan Kardec Afonso Borges*, sem ele dificilmente eu conseguiria fazer esta viagem a um outro país longínquo e poder estudar, a minha mãe *Izaira Dionísia Borges*, mesmo não estando presente hoje em minha vida, deixou-me uma herança de conhecimentos e bons exemplos de vida, não podendo deixar de citar minha namorada a quem amo muito, *Mariana Lima Barbosa* que tanto teve paciência para comigo, me ajudando e me incentivando nos momentos difíceis e alegres da minha jornada e por último sou grato a Deus por ter me colocado essas pessoas em minha vida, sem ele nada disso seria possível.

Agradecimentos

Agradeço as pessoas que fizeram parte da minha vida em Lisboa, cidade onde ampliou meus conhecimentos, ajudando a entender um pouco mais sobre circunstâncias que acontece hoje em minha vida e em possíveis acontecimentos.

*Ajude ao que erra;
seus pés pisam o mesmo chão, e,
se você tem possibilidade de corrigir,
não tem o direito de censurar.*

Allan Kardec

Resumo

Devido à grande demanda de publicações científicas, os investigadores encontram dificuldades em acompanhar novas descobertas dentro de um mesmo domínio. Sintetizando a investigação, seja informalmente ou através de revisões sistemáticas, torna-se cada vez mais intensivo em recursos à medida que as buscas recuperam mais informações potencialmente relevantes, para os revisores avaliarem a relevância da questão e da investigação. Com a necessidade de iniciar uma investigação na área de medicina no campo da genética, uma pequena equipa de investigadores utilizou uma série de palavras-chaves no motor de busca PubMed. Este retornou uma cadeia de artigos, dificultando o processo de triagem, sendo que nem todos estes textos serão relevantes para a revisão de literatura, devido a quantidade e o curto prazo não será possível que os revisores leiam todos em profundidade. Com o trabalho de fazer o processo de triagem de 17.132 artigos, os revisores utilizam para fazer a classificação os rótulos de “relevante” ou “não relevante”, nas informações do campo de título e *abstract*, amenizando assim a carga de ler todo o conteúdo. Com uma quantidade bastante alta de textos, os revisores conseguiram fazer a triagem de 327 artigos, sendo que neste processo, obteve mais artigos classificados como “não relevante” do que “relevante”, formando um *corpus* desequilibrado. Concentrando-se neste problema, é proposto um classificador que apoiará os investigadores na triagem dos artigos, este será treinado de forma supervisionada com os artigos que passaram pela triagem manual, surgindo um pequeno conjunto de treino que serve para treinar o classificador. A fim de solucionar o problema de desequilíbrio, aplica-se a técnica *oversampling*, mostrando ser bastante eficaz quando há poucas informações contidas no *corpus*. Este procedimento de reamostragem possibilita uma melhor abordagem aos artigos com as técnicas de processamento de textos como o *text mining*, viabilizando o uso de outra estratégia denominada *term frequency-inverse document frequency* (TF-IDF). A metodologia utilizada para a qualificação dos artigos é a classificação supervisionada binária, empregando o classificador *support vector machine* (SVM), este mostrou-se eficaz em conjunto com o método probabilístico *latent dirichlet allocation* (LDA), um modelo para descobrir estruturas temáticas ocultas nas coleções de textos, onde o *support vector machine* poderia não ter uma precisão mais exata. Com isso pretende-se demonstrar que, o uso dos métodos de *machine learning* são eficazes na aprendizagem ao auxílio a investigações com revisão sistemática.

Palavras-chave: Aprendizagem Automática; SVM; LDA; Corpus, validação cruzada, *oversampling*, sumarização, revisão de literatura.

Abstract

Due to the great demand for scientific publications, researchers find it hard to follow discoveries within the same domain. Synthesizing the investigation, either informally or through systematic reviews, it becomes increasingly resource-intensive as searches retrieve more potentially relevant information for reviewers to assess the relevance of the issue and the investigation. With the need to start medical research in the field of genetics, a small team of researchers used a series of keywords in the PubMed search engine. That returned a chain of articles, making the screening process more difficult, and not all of these texts will be relevant for the literature review, due to the quantity and in the short term it will not be possible for the reviewers to read them all in-depth. With the task of screening 17,132 articles, the reviewers use the “relevant” or “not relevant” labels to classify the information in the title and abstract fields, thus easing the burden of reading the entire content. With a very high number of texts, reviewers were able to screen 327 articles, and in this process, they obtained more studies classified as "not relevant" than "relevant", forming an unbalanced *corpus*. Focusing on this problem a classifier is proposed that will support researchers in sorting articles, this will be trained in a supervised manner with articles that have gone through manual sorting, with a small set of training that serves to train the classifier. To solve the imbalance problem, the oversampling technique is applied, showing to be very useful when there is little information contained in the *corpus*. This resampling procedure allows a better approach to articles with text processing techniques such as text mining, enabling the use of another strategy called term frequency – inverse document frequency (TF-IDF). The methodology used for the qualification of articles is the supervised binary classification, using the support vector machine (SVM) classifier, which proved to be effective in conjunction with the probabilistic method latent Dirichlet allocation (LDA), a model for discovering thematic structures hidden in collections of texts, where the support vector machine might not be more accurate. This is intended to demonstrate that the use of machine learning methods is effective in learning by assisting investigations with systematic review.

Keywords: Machine Learning; SVM; LDA; *Corpus*, cross-validation, oversampling, summarization, literature review, machine learning.

Índice

1. Introdução.....	15
2. Revisão do estado da arte	18
3. Formulação do problema e solução proposta	22
3.1. Formulação do Problema.....	22
3.2. Classificador para triagem de artigos com base no título e abstract.....	23
3.3. Text Mining	24
3.3.1. Etapas de Text Mining	24
3.3.2. Técnicas de Pré-Processamento em text mining, remoção de caracteres e espaços	27
3.3.3. Tokenização	27
3.3.4. Stopwords.....	28
3.3.5. Normalizando as palavras	29
3.3.6. Lematização	30
3.3.7. <i>Bag Of Words</i> (BoW).....	30
3.3.8. TF-IDF.....	33
3.4. Classificação automática de documentos	34
3.5. Algoritmos de Classificação	35
3.5.1. SVM	35
3.5.2. LDA.....	40
3.5.3. Medidas de desempenho para o algoritmo de classificação.....	44
3.6. Técnica de balanceamento.....	48
3.7. Sumarização de artigos.....	49
4. Apresentação e discussão de resultados	53
4.1. Organização e balanceamento do <i>corpus</i>	53
4.2. Aplicando o modelo probabilístico em conjunto com classificador supervisionado	58
4.3. Extração de características com base na técnica k-fold.....	69

4.4. Discussão dos resultados	75
5. Conclusão	79
5.1. Trabalhos Futuros.....	80
Bibliografia.....	82
Anexo	93
<i>Script</i> utilizado para fazer a recolha dos artigos oriundos do PubMed.....	93
Liste palavras-chave utilizadas no <i>script</i> para poder ter acesso aos artigos vindos do PubMed.	95

Lista de Tabelas

Tabela 1 - Métricas utilizadas para a classificação supervisionada.	44
Tabela 2 - Matriz de Confusão mostrando as categorias.	45
Tabela 3 - Organização de campo do corpus na lista.	53
Tabela 4 - Comparação da classificação entre ambos os tipos de estado do corpus.....	76
Tabela 5 - Comparação da classificação entre ambos os tipos de estado do corpus com suas porcentagens.....	77

Lista de Figuras

Figura 1 - Diagrama ilustrativo da metodologia de Text Mining. Fonte: [61].....	26
Figura 2 - Processo de tokenização seguido por remoção de stopwords.	28
Figura 3 - Exemplo de lista externa para remoção de stopwords da língua inglesa, selecionadas na linguagem Python 3.....	28
Figura 4 - Amostra da tokenização do corpus utilizado neste trabalho.	29
Figura 5 - Exemplo de utilização do método stemming nos termos do texto.	29
Figura 6 - Exemplo de utilização do método de lematização nos termos do texto.	30
Figura 7 - Exemplo de BoW. Elaborado por Oguri et al. Fonte: [71].....	32
Figura 8 - Amostra da BoW a ser utilizado na RS desta dissertação.	32
Figura 9 - Indução de classificador em aprendizagem supervisionado. Fonte: [123].	35
Figura 10 - Exemplo de SVM não linear com como espaço de características. Fonte:[139, 140].....	36
Figura 11 - Representação do hiperplano gerado pelo classificador SVM e suas margens.	37
Figura 12 - Modelo gráfico da distribuição Dirichlet, Adaptada da Fonte: [39]	42
Figura 13 - Função onde pode-se constatar o desenvolvimento da coerência de tópicos Fonte: [91].	48
Figura 14 - Exemplo de técnica Oversampling e Undersampling.	49
Figura 15 - Visualização dos ficheiros que compõem o corpus.....	54
Figura 16 - Ficheiro .xlsx sendo processado para retirada de conteúdos irrelevantes.	55
Figura 17 - Estrutura de repetição para organização da nova lista Python (corpus).	55
Figura 18 - Uma demonstração do conteúdo da lista que se forma com os dois ficheiros.	56
Figura 19 - Corpus em formato dataframe pandas com a coluna index adicionada.	57
Figura 20 - Contagens das classificações antes do balanceamento.....	57
Figura 21 - Contagens das classificações após do balanceamento.....	58
Figura 22 - Pequeno exemplo do dicionário utilizado pelo modelo LDA.	59
Figura 23 - Pequeno exemplo do BoW utilizado pelo modelo LDA contendo somente as referências como id das palavras e seu número de vezes que aparecem no artigo.	60
Figura 24 - Pseudocódigo do modelo LDA. Observação; o parâmetro num_topics é o mesmo termo k.....	61
Figura 25 - LDA em Python, parâmetros que compõem a função LDA.	62
Figura 26 - Tópicos no modelo LDA e o modelo sendo utilizado junto a biblioteca Mallet...	63

Figura 27 - Outra maneira de visualizar os principais tópicos com uso do pacote Python, pyLDavis.	64
Figura 28 - Pontos de Coerência e Valor da coerência.	65
Figura 29 - Pontuações de coerência.	65
Figura 30 - Métricas utilizadas de Perplexidade e Coerência do modelo LDA e Mallet.	66
Figura 31 - Documento mais representativo para cada tópico.	66
Figura 32 - Ilustração do Ciclo de um Grid-Search na busca de Parâmetros Ótimos [115]. ...	67
Figura 33 - Classes sem nem um tipo de ajuste do hiper-parâmetros.	68
Figura 34 -Classes com ajuste do hiper parâmetros.	68
Figura 35 - Hiper-parâmetros ajustado e com kernel linear.	68
Figura 36 - Exemplo de implementação da técnica de validação cruzada k-folds.	71
Figura 37 - Demonstração da extração de recurso dos artigos com a medida estatista TF-IDF.	71
Figura 38 - A função é chamada pelo vetor vectorizer que é o modelo advindo da função TfidfVectorizer, esta função leva como parâmetro, X_train e X_test.	72
Figura 39 - Extração dos rótulos de polaridade da classificação.	72
Figura 40 - Algoritmo da técnica k-folds, elaborado em algoritmo estruturado (Portugol). Demonstração das interações da validação cruzada com o classificador e o método TF-IDF.	73
Figura 41 - Diagrama de Fluxograma representando cada etapa do algoritmo classificador. .	75
Figura 42 - Matriz de confusão com o corpus balanceado e não balanceado e suas métricas.	75
Figura 43 - Sumarização dos artigos, abrangendo os Abstract de cada documento.	77
Figura 44 - Conteúdo do artigo com índice 16474 antes da sumarização.	78
Figura 45 - Reconhecimento de entidades na sumarização dos Abstracts.	78

Lista de Siglas e Acrónimos

BOW	Bag Of Words
IDF	Inverse Document Frequency
TF-IDF	Term Frequency - Inverse Document Frequency
LDA	Latent Dirichlet Allocation
NLTK	Natural Language Toolkit
RNA	Redes Neurais Artificiais
SVM	Support Vector Machines
NLP	Natural language processing
MeSH	Medical Subject Headings
EN	Entidades Nomeadas
RS	Revisão Sistemática

1. Introdução

Uma característica primordial da ciência moderna é ser uma realização cumulativa. O conhecimento alcançado em cada momento baseia-se no vasto *corpus* de conhecimentos descobertos e comunicados anteriormente. Cada investigador pode fazer eco das célebres palavras de Isaac Newton: “*If I have seen further it is by standing on the shoulders of giants*” [1]. Por esta razão, as revisões de, ou seja, sínteses daquilo que de mais relevante é conhecido sobre um determinado tópico, são cruciais em ciência [2]. Com elas torna-se possível determinar se o que foi publicado numa determinada área permite identificar padrões ou tendências interpretáveis, agregar resultados empíricos de forma a permitir prática baseada em evidência (por exemplo em medicina), criar novas teorias, ou descobrir questões que necessitam de mais investigação [3].

Existem dois tipos de revisão de literatura [4]: o primeiro e mais comum é àquele que se faz em qualquer artigo científico ou dissertação, e que em seções intituladas, por exemplo, “estado da arte” procura sintetizar o que existe publicado sobre o tópico de interesse, podendo também fornecer o contexto do problema a abordar e fornecer o quadro teórico para a solução proposta para o problema identificado [5]. O segundo tipo denomina-se revisão sistemática de literatura e é em si mesmo um trabalho de investigação. Nele procura-se sintetizar de forma completa e rigorosa uma determinada área científica, procurando eliminar o mais possível qualquer subjetividade na escolha dos trabalhos a referir. Um artigo de revisão sistemática de literatura pretende ser um ponto de partida para os membros de uma determinada comunidade científica sem que haja lugar à análise de quaisquer dados primários [6].

Nas áreas do saber onde o tempo é um fator crucial, por ser urgente a obtenção do conhecimento, as revisões sistemáticas de literatura assumem uma importância especial, pois colocam as equipas de investigação na fronteira do conhecimento e na posse de uma panorâmica segura do que foi realizado no passado. Tal é o caso das ciências da vida. Por exemplo, na gestão da atual pandemia de Covid-19, revisões sistemáticas aceleradas têm sido produzidas, nomeadamente, para a obtenção de evidência científica relativa à utilização de máscaras [7] ou relativa ao efeito da Covid-19 na gravidez [8], entre muitas outras. Da mesma maneira, quando se fazem avaliações de tecnologias em saúde, nomeadamente fármacos, a realização de revisões sistemáticas tão rápidas quanto possíveis é essencial para doentes, médicos, e indústria [9].

Nas últimas décadas o número de artigos científicos publicados globalmente tem tido taxas de crescimento de cerca de 8% [10]. Nas ciências da vida esse crescimento tem até sido

um pouco superior [10]. No PubMed, o repositório mais utilizado de artigos nas ciências da vida (mas que não representa a totalidade do que é publicado), são depositados anualmente mais de 1 milhão de artigos [11]. Perante o crescimento exponencial de publicações, compreende-se que a elaboração de revisões sistemáticas de literatura seja uma tarefa que consome muito tempo, e recursos (humanos e financeiros), tendo uma duração média que pode ir dos 6 meses a vários anos [12,13].

O desenvolvimento do método de *machine learning* para semi-automatizar a elaboração de revisões sistemáticas de literatura tem sido um foco de interesse nos últimos anos, constituindo a sua própria subárea de investigação e desenvolvimento [14], e existindo até revisões sistemáticas de literatura sobre este mesmo assunto, *e.g.*, [15,16]. A maior parte dessas técnicas realiza classificação de texto, extração de dados ou ainda sumarização [17]. A classificação de texto visa desenvolver modelos que permitem organizar automaticamente os documentos de acordo com um conjunto pré-definido de categorias (por exemplo, está relacionado com a doença de Alzheimer verso não está relacionado com essa doença). Os modelos de extração de dados têm como objetivo identificar palavras/números ou pequenos excertos de texto que correspondem a uma determinada informação pretendida (por exemplo, uma fórmula química que representa uma proteína no caso de se pretender extrair referências a proteínas, ou extrair o número de pessoas que participam num dado ensaio clínico). A sumarização pretende sintetizar um novo documento de texto cujo conteúdo constitua um resumo do documento original.

Esta dissertação tem como objetivo apresentar uma solução de *machine learning* para semi-automatizar o processo de elaboração de uma revisão sistemática de literatura subordinada ao tema “Qualidade de vida em doentes com *Congenital Disorders of Glycosylation* (CDG) e suas famílias”. Em qualquer revisão sistemática de literatura começa-se por definir um conjunto de critérios de inclusão/exclusão de artigos a considerar. Desses critérios faz parte um conjunto de palavras chave e (combinações das mesmas) que se escolhe de modo a realizar uma extração inicial de artigos de um repositório. Naturalmente essa extração é muito grosseira pelo que o conjunto de artigos assim obtidos, que usualmente tem uma dimensão da ordem das dezenas ou centenas de milhar, tem uma elevada percentagem de artigos que não são relevantes para a revisão de literatura pretendida.

Um passo fundamental na elaboração de uma revisão de literatura é a realização de uma triagem inicial com base nos *abstracts* dos artigos desse conjunto. Esta triagem representa um compromisso: avaliar a totalidade dos artigos, mas apenas com base no seu *abstract* e título. Deste modo consegue-se diminuir substancialmente o número de artigos com um esforço

moderado pela limitação à análise do resumo do artigo. Devemos referir que, não obstante este compromisso, esta é ainda assim uma tarefa que representa um grande esforço e normalmente muito demorada. Esta dissertação apresenta um modelo de *machine learning* para automatizar esta triagem com base nos títulos e resumos dos artigos.

2. Revisão do estado da arte

Atualmente os desafios nas investigações sugerem a procura de novas técnicas, novas ideias, levando a área científica a criar meios para o surgimento de novas tecnologias. Para a inicialização aos conceitos de aprendizagem automática na revisão sistemática de literatura, são apresentados neste capítulo algumas das revisões sobre obras vinculadas, empregando os métodos de *machine learning* e também os princípios da sua abordagem e os meios para um bom desenvolvimento do tema.

A revisão sistemática de literatura tem como objetivo identificar, analisar e interpretar as evidências disponíveis, relacionadas com um particular tópico de pesquisa ou fenômeno de interesse, sendo um dos principais meios para evidenciar sumarização[18], fazendo com que este método se torne cada vez mais popular conforme pode ser constatado em trabalhos como[18, 19].

Este método de processo de descoberta de conhecimentos nos textos, é muito utilizado atualmente em campos de pesquisas de história, área médica, biomédica e farmacêutica [20, 21]. De acordo com autores em [22] a revisão sistemática (RS) teve origem na área da Medicina, tornando-se um método de investigação chave baseado em factos. As investigações para este tipo, mostraram que as opiniões de especialistas baseadas apenas nas suas experiências médicas, não eram tão verdadeiras quanto em comparação com as bases em resultados de experimentos científicos, ou seja, nas evidências.

Com o desenvolvimento do método de RS, houve um acréscimo de resultados positivos fazendo com que muitos especialistas passassem a adota-la. Em 2004 houve uma conformidade com o que é praticado na área medica, propondo procedimento em processos para a realização da RS na Engenharia de Software [23]. Em [24] os autores mostram que a RS se torna o método de pesquisa mais conhecido quando se trata de sumarização e evidências na Engenharia de Software e na Ciência da Computação, ocasionando um crescimento de forma significativa do seu uso nos últimos anos [18,19,24].

Para a evolução da RS, investigadores e formuladores de políticas de saúde, auxiliam cada vez mais no desenvolvimento deste método. Como já mencionado anteriormente, a conduta da RS pode ser uma tarefa demorada, colocando aos desenvolvedores de prática clínica ou outros tomadores de decisões, a necessidade de tomar as decisões informadas em tempo hábil, como exemplo: surtos de infecção, avaliações de tecnologias de saúde em hospitais. Para que haja uma precisão nas questões de produção de RS, foram analisadas as seguintes questões:

(a) implementar paralelização de processos (exemplo, ter dois ou mais revisores humanos para poder fazer a triagem dos artigos), (b) adaptar e aplicar tecnologias inovadoras (c) modificar processos de RS (por exemplo, critérios de elegibilidade do estudo, fontes de pesquisa, dados de extração ou avaliação da qualidade) [12].

Na questão (b), da implementação de RS com uso de novas tecnologias é um assunto que está recebendo destaque cada vez mais, diante da importância do seu aperfeiçoamento, pois contribui na redução da carga de trabalho, melhorando a eficiência na produção, porém de acordo com [12] as novas tecnologias precisam ser avaliadas quanto à precisão, confiabilidade, praticidade e custo. Os autores em [25] ilustram a questão (b), mostrando que instrumentos como catálogos *on-line* como o sitio *System Review (RS) Toolbox*, fornece uma lista de ferramentas, dando a possibilidade de fazer download para o apoio a RS, comprovando o emprego de meios tecnológicos para este tipo de situação. Um exemplo disso é o uso de ferramentas de tecnologia tais como o método de *machine learning*, nas áreas que permitem a automação de processos específicos de RS, em particular aquelas que envolvem tarefas demoradas e que consomem recursos, como tradução de idiomas[12,26], seleção de estudos, extração de dados e avaliação de risco de viés[12].

Em [27] os autores propõem a avaliação do uso do *DistillerAI*, esta é uma ferramenta incorporada ao software de revisão de literatura do *DistillerSR* [28] um software *web* e disponibilizado comercialmente. Os autores em [27] montam cinco equipas de revisores sistemáticos que selecionam 2472 artigos propostos em paralelo, sendo que cada uma dessas equipas treinou a ferramenta *DistillerAI* que substituiu um revisor humano de cada equipa e forneceu previsões sobre a relevância dos registos

O resultado obtido em [27] desta ferramenta, mostrou que sua sensibilidade para triagem assistida por softwares nas cinco equipas, tornou-se inadequada para substituir temporariamente um revisor humano durante a triagem de artigos para RS, tornando esta ferramenta mais adequada para revisões rápidas, não exigindo detecção da totalidade das evidências relevantes, colocando as ferramentas de semi-automação em uma escala utilidade mais elevada que as revisões tradicionais.

Para resolver essas questões propostas pelos autores em [27], onde nem sempre ferramentas para fazer RS são adequadas, novos tipos de possibilidades de aquisições de informações foram criados, como exemplo, o motor de busca PubMed onde os investigadores podem ter meios mais fáceis de encontrar artigos baseados em biomedicina, contudo para que haja uma boa prática do método de RS, esses dados colhidos não podem ser desequilibrados, utilizando para isso métodos e técnicas de processamento e classificação de texto.

Em [29] os autores demonstram que mesmo investigadores experientes têm dificuldades na hora de fazer triagens em motores de busca do gênero do PubMed, estes nem sempre dão a oportunidade de encontrar informações para compor um *corpus* balanceado, sendo necessário empregar novas tecnologias, utilizando procedimentos que elaboram consultas de palavras-chave, dando aos investigadores um número mínimo de artigos relevantes para as questões investigadas, gerando uma quantidade maior de artigos não relevantes, ocasionando na investigação o desequilíbrio de dados.

Em situação como esta, os usos de métodos de *machine learning* podem ajudar a minimizar o desequilíbrio dos dados colhidos. Isto pode ser constatado em [17,29]. Em [30] os autores elaboram métodos de investigação para o processamento dos textos colhidos, onde mostram os treinos de quatro tipos de classificadores binários como: SVM, vizinho k-mais próximo, floresta aleatória e modelos lineares generalizados com rede elástica, apresentando as combinações destas quatro técnicas, que podem solucionar ou amenizar o problema de desequilíbrio de classes através do processamento de texto utilizando técnicas de *text mining* [29].

Uma semelhança que pode ser constatada em [30], onde os investigadores utilizaram o motor de busca PubMed para fazer a triagem, sendo feita a redução da carga de trabalho em revisões pré-clínicas de estudos com animais, estes aplicaram duas abordagens independentes de *machine learning*, para rastrear um grande número de citações. Na primeira abordagem utilizaram os recursos como o modelo *n-grams* para formar a amostra de representação de textos chamado de *Bag of Words* (BoW), e o classificador SVM com *stochastic gradient descent* (SGD) para classificar as amostras. Na segunda abordagem é feita a utilização do modelo probabilístico conhecido por *latent dirichlet allocation* (LDA) com *singular value decomposition* (SVD) mostrando a importância das palavras num determinado artigo, utilizando a medida estatística *TD-IDF*. Com isso pode-se concluir que para fazer a RS de artigos utilizando as novas tecnologias, não há um único modo, mas sim a melhor escolha para cada situação que possa resolver a questão do apoio a RS.

Para a elaboração do classificador da aprendizagem automática na RS nesta dissertação, a solução proposta se baseia em *machine learning* e terá forte integração com as técnicas de *text mining*, facilitando a redução da carga de trabalho na realização de RS. Em [31] define que *text mining* é um conjunto de processos que descobre conhecimento inovador no texto, estando nesta dissertação acompanhada do uso das técnicas de NLP uma técnica computacional envolvendo linguagens [32].

As técnicas de *text mining* em conjunto com NLP, ajudam no processo de descoberta de conhecimento e geração de hipóteses, ocasionando o volume da literatura [33]. O principal objetivo da junção destas duas técnicas neste trabalho é extrair novas informações, como relações ocultas nos textos entre entidades nomeadas, facilitando para que investigadores descubram sistematicamente e eficientemente, coletando, interpretando e organizando o necessário para a investigação [34].

O auxílio na redução da carga de triagem, utiliza dos métodos de *machine learning*, estes métodos ajudaram na aprendizagem do computador, com base na triagem manual, empregando dois tipos de medidas; “relevante” e “não relevante” [35]. Para empregar a classificação automática é utilizada a estratégia de aprendizagem supervisionada, técnica esta que pode começar com um pequeno conjunto de treinamento e por meio de iteração, a coleção de dados é aumentada de tamanho e utilidade, mas para este trabalho os números de artigos são fixos [34,36].

O desenvolvimento da aprendizagem supervisionada, propõe o emprego do classificador SVM para a realização da classificação das instâncias. Este classificador é um dos mais utilizados quando se trata de treinamento supervisionado, encontrando um hiperplano que separa as instâncias de treinamento do não relevante para o relevante por um limite máximo de margem [37]. Para um bom aprimoramento da classificação supervisionada, antes é empregado a técnica de LDA. Os autores em [20,39] demonstram que a técnica LDA é um modelo probabilístico baseado num conjunto de algoritmos cujo objetivo é descobrir estruturas temáticas ocultas em grandes coleções de documentos. A ideia do ocultismo nas estruturas temáticas é a necessidade de mostrar termos que poderiam passar por despercebido por outras técnicas como o *TF-IDF*. O LDA distingue os textos como uma mistura de distribuições de tópicos ocultos, sendo que cada tópico é representado por um valor flutuante, mostrando ser promissor quando poucas informações atribuídas manualmente estão disponíveis, formando *clusters* das informações a serem analisadas, aumentando o desempenho da aprendizagem ativa sem anotação manual.

Logo adiante é explanado com mais detalhes o desenvolvimento da solução em *machine learning* para semi-automatizar o processo de RS, ajudando na busca e organização dos artigos a que se pretende fazer possíveis investigações sobre o tema desejado, sendo explicando com maiores detalhes as tecnologias utilizadas e seus métodos de utilização.

3. Formulação do problema e solução proposta

A taxa de publicação da investigação está a aumentar extraordinariamente na área da saúde, especialmente em Medicina [40]. Para os investigadores que necessitam cada vez mais de informações em tempo rápido, eles têm dificuldade em acompanhar novas descobertas, mesmo que sejam dentro de um único domínio, uma questão que vem surgindo há vários anos [41]. A RS fica cada vez mais abundante em recursos à medida que as buscas recuperam um número maior de artigos potencialmente importantes para que os revisores examinem a relevância da questão da investigação [42].

A solução que muitos investigadores vêm recorrendo para que esta carga de trabalho seja reduzida em tempo menor, está baseada na área de *text mining* sendo uma subárea de *machine learning*, facilitando a realização da RS em diversas áreas do conhecimento [18, 42]. O uso de técnicas de *text mining* e métodos de *machine learning* para auxiliar a RS, vem se mostrando bastante eficaz. Está se tornando uma abordagem cada vez mais comum para limitar a carga humana e os recursos monetários necessários e diminuir o tempo para concluir essas revisões [47].

Neste trabalho foram utilizadas informações oriundas do PubMed, um motor de busca utilizado para acessar citações e resumos de artigos de investigações na área da Biomedicina, o qual utiliza em sua base de dados outro sistema de busca e análise de literatura médica, o MEDLINE, sendo sua fonte, a base de dados bibliográfica da biblioteca nacional dos Estados Unidos da América [43,44].

3.1. Formulação do Problema

Os investigadores quando fazem a seleção de artigos para iniciar seus estudos, encontram dificuldades de realizar a triagem dessas informações pelo motivo que, ao se fazer a investigação em motores de busca utilizando palavras-chave, este retorna uma cadeia de artigos dos quais muitos serão irrelevantes para o estudo da RS, dificultando aos revisores lerem todos em profundidade em curto prazo de tempo [45, 46]. Com este problema os revisores que formaram o corpus empregue nesta dissertação, selecionaram um conjunto de palavras-chave específicas do campo de estudos pré-clínicos introduzidas no PubMed, este retornou uma quantidade de 17.132 artigos sendo que muitos desses artigos se mostraram desinteressantes para a equipa de investigadores. Estes artigos não apropriados para a classificação da triagem

correspondem aquelas palavras-chave encontradas em campos de estudos de outras áreas vinculadas a Biomedicina. Para classificar o montante de artigos colhidos, os revisores conseguiram obter 327 artigos dos quais somente 265 são classificados como desinteressante e 62 artigos são classificados como relevante, isto demonstra que a escolha das palavras-chave tem importância para poder obter do motor de busca PubMed os textos que possa ser interessante para os investigadores, com isso evitando desperdício de tempo e possivelmente o desequilíbrio das informações.

3.2. Classificador para triagem de artigos com base no título e abstract

O processo de classificação de artigos é fundamentado nos campos de título e *abstract*, sendo empregado os métodos de *machine learning* com sua técnica de classificação SVM. Para a formação do *corpus* utilizado nesta dissertação, se fez necessário desenvolver um *script* em linguagem Python 3. Este acessa o conteúdo do PubMed através dos campos de título, *abstract* e MeSH (do inglês *medical subject headings*) [52]. Com uma folha de cálculo contendo três classes de palavras-chave (vide anexo), o *script* faz combinação de duplas e triplas das palavras-chave, sendo uma de cada classe.

Para o processo de triagem utilizado pelos revisores, foram aplicados dois critérios de avaliação, sendo em “relevante” e “não-relevante”, possibilitando o emprego da técnica de classificação supervisionada.

A fim de auxiliar o classificador, faz-se uso das técnicas de processamento de textos onde são aplicados os procedimentos de *text mining* em conjunto com os processos de PNL, tornando possível utilizar as representações dos artigos num conjunto de palavras com suas frequências no texto. Para esta representação é utilizado o modelo BoW, este modelo não ajuda na classificação do conteúdo, porém deixa uma base de medidas estatísticas para poder ser usado pela técnica *TF-IDF* [20, 50, 51, 53].

Com essa implementação de processamento de texto, torna-se possível fazer uso do modelo LDA, este se mostra promissor quando poucas informações atribuídas estão disponíveis, aumentando o desempenho do aprendizado supervisionado sem anotação manual, ajudando nas representações dos artigos, expondo os textos que contenham informações ocultas que possa passar despercebido pelo classificador [54].

Para a classificação dos artigos com a técnica SVM é necessário a matriz termo-documento, sendo esta uma matriz de vetores de recursos, com contagem de palavras equilibradas pela técnica *TF-IDF* de comprimento fixo. Essa matriz que contém a classificação

dos artigos, é uma lista com um pequeno conjunto para treinar o classificador supervisionado. Com esses procedimentos mencionados acima, é possível utilizar o classificador de artigos para auxiliar a aprendizagem ao apoio a RS.

3.3. Text Mining

Text mining é o processo de descoberta de informações em grandes coleções de textos e identifica automaticamente padrões e relacionamentos interessantes em dados textuais [31]. Esta descoberta de conhecimento envolve diversas aplicações tais como análise de textos, extração de informações, sumarização, classificação, agrupamentos, linguística computacional, dentre outras.

Text mining usa técnicas de *information retrieval*, que envolve recuperar informações de dados armazenados através de consultas de utilizadores ou perfis de utilizadores pré-formulados [55]. Sendo uma área de investigação relativamente nova que recentemente levantou muito interesse no meio industrial e nas comunidades científicas, principalmente devido à crescente quantidade de informações disponíveis na internet, está vindo a ajudar a desenvolver melhor a RS [20, 49, 56, 57].

3.3.1. Etapas de Text Mining

Uma das etapas do processo de *text mining* é o estágio para a técnica de classificação de textos, esta é gerida pela coleta de dados em forma de textos através da extração dos documentos que podem ser das mais variadas fontes, tais como e-mails, campos textuais em banco de dados, páginas web, textos eletrônicos digitalizados, etc [49,56,58,59].

Existem algumas fases que são de suma importância aos processos de *text mining*, as quais podem ser citadas como: (1) extração, (2) pré-processamento de textos, (3) transformação, (4) mineração, por último (5) análise [42, 60].

- Extração: A extração é a fase principal da técnica de *text mining*, estando esta parte como a base de todo o processo do desenvolvimento deste trabalho, neste segmento há o serviço de coleta de textos, que podem ser de várias maneiras, alguns utilizam de software de terceiros como o *Crawlers*, um software que percorre sítios da internet com o intuito de coletar automaticamente os dados, mas neste trabalho o modo de extração de conhecimento foi baseado em

pesquisas de triagem onde foram utilizados de dois revisores humanos para fazer pesquisas em cima de artigos colhidos de variadas fontes e depois sendo classificados como “relevantes” ou não relevantes. Depois de colhidos os dados suficientes para análise, é possível criar um corpus que servirá de base para aplicar as técnicas de *text mining* em conjunto com as técnicas de *machine learning* [61, 62].

- Pré-processamento de textos: Nesta fase os textos oriundos da Extração são processados para eliminar redundâncias e filtrar informações irrelevantes que possam causar distúrbios nas informações desejadas, tipos de distúrbios que possam ser detetados são: espaços, pontuações irrelevantes, caracteres especiais que confundem o algoritmo na hora da aprendizagem. Essa fase costuma consumir muito tempo de processamento na hora da extração de conhecimento, por não existir uma única técnica que possa ser aplicada em todos os domínios de aplicação, variando muito do corpus a ser utilizado [63].
- Transformação: Depois de passado pela fase 1 e 2, essa parte fica a cargo de averiguar se as informações textuais estão íntegras no sentido de que, se há a necessidade de modificar ou não o corpus, em que os artigos colhidos e classificados foram juntados. Contudo em muitas vezes, alguns trabalhos de *text mining* e classificação de textos, precisam de redução de dimensionalidade ou mesmo aumento em sua estrutura, necessitando assim em algumas vezes de adicionar rótulos (*labels*), como exemplo: a criação de índice para acesso mais rápido, organizando assim melhor o conteúdo do corpus internamente, isso quando não há a necessidade de fazer um balanceamento no conjunto de textos que compõem o corpus por motivos de má classificação entre as classes, gerando assim uma tendência de pontuação maior para as classes majoritárias[57].
- Mineração: Fase em que a aprendizagem de máquina é aplicada para obter os conhecimentos desejados, sendo esta direcionada para o caso em que pretende-se trabalhar, por exemplo: se o investigador precisar de investigar graus de similaridade em formação de grupos, então o algoritmo de mineração escolhido é o de *clusterização*, por outro lado, se o mesmo investigador precisar de averiguar informações já formadas em que o conhecimento prévio baseia-se em

rótulos, o método mais claro para o desenvolvimento da mineração será a classificação. Para este trabalho, é utilizado o método de classificação onde são encontrados os principais artigos pertencentes as diferentes classes, ajudando na seleção de textos que se pretende obter com maior agilidade [49 ,63].

- **Análise:** Segundo[49] a análise é a eficiência do resultado de processos em que se pretende obter após as aplicações de fases anteriores, sendo a etapa em que é avaliado o objetivo de descobrir novos conhecimentos a partir da base de dados que foi criada ou seja, o corpus. Este é um processo cíclico em que cada etapa é analisada individualmente, para saber se é satisfatório ou não, se caso este não seja satisfatório é realizado um novo ciclo de processos.



Figura 1 - Diagrama ilustrativo da metodologia de Text Mining. Fonte: [61].

Na Fig. 1, pode ser observado o ciclo de vida dos processos de *text mining*. Como a fase de pré-processamento é exaustiva, após a coleta dos textos, será reservado nas seções abaixo envolvendo o detalhamento mais preciso desta técnica com o intuito de alcançar melhor compreensão sobre essa parte que é tão necessária quando se trata de *text mining* para a RS.

3.3.2. Técnicas de Pré-Processamento em text mining, remoção de caracteres e espaços

Esta etapa é considerada uma fase da pré-tokenização, um termo utilizado para indicar o início da fragmentação de uma sequência textual em palavras ou elementos significativos, denominados de *tokens* [65]. A etapa de pré-tokenização, filtra qualquer tipo de caracteres desnecessários que possam causar ruído no processamento do corpus. Quase sempre, essa etapa de remoção de caracteres de nova linha ou símbolos especiais, é feita com a utilização de técnicas chamadas de expressões regulares também conhecidas como *regex*, as quais constituem uma linguagem para pesquisar, extrair e manipular padrões de *strings* específicas em textos. É amplamente utilizado em projetos que envolvem validação de texto, NLP e *text mining* [61, 64].

3.3.3. Tokenização

A tokenização é o processo de dividir uma sequência textual em palavras ou elementos significativos, chamados de *tokens*. O termo *token* será bastante utilizado nesta dissertação, visto que, em alguns momentos, ele poderá possuir o mesmo sentido da “palavra”. De facto, na maioria das vezes, um *token* representa uma palavra no *corpus* [66].

A utilização de métodos como a tokenização pode trazer certos tipos de problemas como exemplo o uso do “espaço em branco” que em certas línguas não se utiliza o espaço como delimitador, como por exemplo, em japonês ou chinês [62]. Um outro problema que é causado pela utilização da tokenização, é a dimensionalidade das palavras, uma vez que a divisão do texto em palavras leva à criação de grandes números de dimensões para análise, mas que poderá ser corrigido com técnicas de redução de dimensionalidade [63].

Uma visualização simples deste facto é utilizada na seguinte frase de Fernando Pessoa: “Navegar é preciso”. Tokenizando a frase, resultam três *tokens*: [Navegar], [é], [preciso]. A decomposição em *tokens* facilita a análise do texto, porém segundo [63] essa divisão em *tokens* cria inúmeras dificuldades sendo necessário utilizar outras técnicas como *streaming*, lematização e a remoção de *stopwords*, que a seguir será descrito brevemente.

3.3.4. Stopwords

Stopwords são palavras dentro do texto com pouca utilização, fornecendo muitos *tokens* que não possuem valor para o contexto, sendo úteis para uma compreensão geral do texto. Em [57] menciona que, *stopwords* são palavras vazias, estando representadas por artigos, preposições, pontuações, conjunções e pronomes de uma língua específica. [67] considera que além de não ajudar na análise de classificação do texto, surgem em praticamente todo o conteúdo do texto, exemplo deste facto na língua portuguesa: “a”, “e”, “de”, “mas”, “com”, dentre outras. Com a remoção desses *tokens*, há um ganho no desempenho na RS como um todo, reduzindo o tamanho do léxico consideravelmente [68]. Na Fig. 2 pode se observar melhor este processo seguido por remoção de *stopwords*.




Figura 2 - Processo de tokenização seguido por remoção de stopwords.

A Fig. 3 mostra um trecho do código do classificador onde tem uma pequena lista com as palavras escolhidas para serem excluídas no processo de *stopwords*.

```
# NLTK Stop words
from nltk.corpus import stopwords
stop_words = stopwords.words('english')

#Essa lista de palavras básicas da língua inglesa está sendo montada para ser exclusivamente forçada a sua exclusão
#Com isso é esperado um maior acerto na classificação dos tópicos e os seus documentos. Obs: pode ser acrescentado
#mais palavras a tal lista se for necessário
stop_words.extend(['from', 'subject', 're', 'edu', 'use', 'not', 'would', 'say', 'could', '-',
    'be', 'know', 'good', 'go', 'get', 'do', 'done', 'try', 'many', 'some', 'nice',
    'thank', 'think', 'see', 'rather', 'easy', 'easily', 'lot', 'lack', 'make',
    'want', 'seem', 'run', 'need', 'even', 'right', 'line', 'even', 'also', 'may',
    'take', 'come'])
```

Figura 3 - Exemplo de lista externa para remoção de stopwords da língua inglesa, selecionadas na linguagem Python 3.

Na Fig. 4, pode-se constatar como é a organização interna do corpus que foi processado pela técnica de tokenização.

```
In [7]: print(data_words)

[['studies', 'in', 'the', 'modified', 'scoliosis', 'research', 'society', 'outcomes', 'instrument', 'in', 'adults', 'validation', 'reliability', 'and', 'd', 'capacity', 'study', 'design', 'observational', 'study', 'of', 'patients', 'with', 'scoliosis', 'and', 'matched', 'controls', 'objectives', 'to', 'determine', 'y', 'and', 'reliability', 'of', 'the', 'modified', 'scoliosis', 'research', 'society', 'outcomes', 'instrument', 'srs', 'for', 'use', 'in', 'the', 'assess', 'mity', 'in', 'adults', 'to', 'demonstrate', 'the', 'discriminate', 'validity', 'of', 'the', 'srs', 'in', 'differentiating', 'between', 'affected', 'and', 'ts', 'summary', 'of', 'background', 'data', 'spinal', 'deformity', 'has', 'an', 'important', 'impact', 'on', 'the', 'general', 'health', 'status', 'of', 'gnitude', 'of', 'this', 'impact', 'has', 'been', 'difficult', 'to', 'measure', 'and', 'reported', 'variably', 'in', 'the', 'literature', 'the', 'developme', 'e', 'specific', 'outcomes', 'tools', 'permits', 'improved', 'sensitivity', 'and', 'specificity', 'in', 'measuring', 'the', 'patient', 'self', 'assessment', 'status', 'an', 'instrument', 'for', 'measuring', 'disease', 'specific', 'health', 'status', 'in', 'adults', 'with', 'scoliosis', 'has', 'not', 'been', 'v', 'ls', 'and', 'methods', 'observational', 'study', 'comparing', 'the', 'health', 'status', 'of', 'adults', 'affected', 'by', 'scoliosis', 'and', 'unaffected', 'ched', 'for', 'age', 'gender', 'and', 'socioeconomic', 'status', 'pearson', 'correlation', 'analysis', 'was', 'used', 'to', 'determine', 'the', 'relations', 'domain', 'within', 'the', 'srs', 'and', 'sf', 'with', 'radiographic', 'parameters', 'including', 'sagittal', 'balance', 'coronal', 'balance', 'and', 'maj', 'ection', 'discriminate', 'validity', 'of', 'the', 'modified', 'srs', 'instrument', 'was', 'determined', 'by', 'comparison', 'of', 'means', 'between', 'aff', 'fected', 'cohorts', 'the', 'validation', 'of', 'the', 'srs', 'was', 'determined', 'by', 'criterion', 'validity', 'using', 'correlation', 'analysis', 'wit', 'domains', 'of', 'the', 'sf', 'the', 'reliability', 'of', 'the', 'srs', 'was', 'demonstrated', 'using', 'test', 'retest', 'parity', 'and', 'cronbach', 'al', 'r', 'internal', 'consistency', 'results', 'one', 'hundred', 'eighty', 'adults', 'were', 'included', 'in', 'the', 'study', 'with', 'scoliosis', 'and', 'wit', 'ith', 'scoliosis', 'scored', 'significantly', 'lower', 'than', 'unaffected', 'controls', 'on', 'every', 'domain', 'of', 'the', 'srs', 'and', 'the', 'sf', 'd', 'ceiling', 'effect', 'of', 'the', 'srs', 'were', 'less', 'than', 'observed', 'in', 'the', 'sf', 'instrument', 'pearson', 'correlation', 'analysis', 'd', 'significant', 'correlation', 'between', 'any', 'radiographic', 'process', 'measure', 'and', 'any', 'specific', 'domain', 'within', 'the', 'srs', 'or', 't', 'son', 'of', 'similar', 'domains', 'in', 'the', 'srs', 'and', 'the', 'sf', 'demonstrates', 'high', 'correlation', 'between', 'the', 'instruments', 'test', '']
```

Figura 4 - Amostra da tokenização do corpus utilizado neste trabalho.

3.3.5. Normalizando as palavras

A técnica de normalização das palavras nos textos, pode ser considerada como um conjunto de técnicas de pré-processamento de texto, reduzindo o léxico que identifica e agrupa as palavras que possuem relações entre elas. Como há uma grande variação de escopo, a normalização das palavras usa de diversas técnicas para realizar essa tarefa, destacando-se os processos de *stemming* e lematização. Para esta dissertação será utilizado a técnica de lematização pelo facto que uma mesma palavra pode ter diversos significados dentro de um contexto. A lematização ajuda a distinguir essa parte reduzindo a palavra ao seu radical primário, enquanto que o método *stemming* não usa, por exemplo informações do contexto para determinar o sentido correto de cada termo, reduzindo o termo flexionado (ou às vezes derivado) ao seu tronco, base ou raiz, geralmente uma forma da palavra escrita não sendo necessário ter um significado para o contexto [31, 69]. Abaixo na Fig. 5 é exemplificado como fica uma palavra com o processo *stemming*.

'Olhar' => *stemming* => 'Olh'

'Gritando' => *stemming* => 'Grit'

Figura 5 - Exemplo de utilização do método stemming nos termos do texto.

3.3.6. Lematização

Lematização é o processo de converter uma palavra em sua forma base, voltando ao seu radical, deixando-a no modo infinitivo do verbo, através da remoção de sufixos, permitindo mostrar a sua semântica visando reduzir o problema de textos redundantes. O uso de palavras em contextos de lematização, pode ajudar na distinção tanto de palavras invisíveis quanto ambíguas, ou seja, suponha-se que em uma frase seja utilizada uma palavra cuja sua raiz é um verbo, sendo empregado em algum modo de transição verbal, causando em certas situações redundância [69, 70]. Segue abaixo um exemplo de como a lematização é empregada para fazer a redução das palavras a sua forma raiz sem perda de sentido do termo, veja Fig. 6.

'Olhando' => Lematização => 'Olha'

'Gritando' => Lematização => 'Grita'

Figura 6 - Exemplo de utilização do método de lematização nos termos do texto.

3.3.7. *Bag Of Words* (BoW)

BoW é um modelo que ignora a ordem das palavras assim como qualquer informação de pontuação ou estrutural, mas retém o número de vezes que a palavra aparece no texto, sendo representada como uma matriz de termo-documento [31]. Para ficar mais claro como a técnica BoW age, é demonstrado um trecho de dois textos (poemas) do autor Carlos Drummond de Andrade.

Texto 1(*No meio do caminho*):

*No meio do caminho tinha uma pedra
tinha uma pedra no meio do caminho
tinha uma pedra*

..

.

Texto 2(*Quadrilha*):

João amava Teresa que amava Raimundo

*que amava Maria que amava Joaquim que amava Lili,
que não amava ninguém.*

Utilizando o modelo BoW para representar os textos, mostra os poemas como vetores onde são contados o número de vezes que cada palavra aparece,

Texto1: [[('caminho', 2), ('do', 2), ('meio', 2), ('no', 2), ('pedra', 3), ('tinha', 3), ('uma',3)]]

Texto 2: [[('amava', 6), ('joaquim', 1), ('joão', 1), ('lili', 1), ('maria', 1), ('ninguém', 1), ('não', 1), ('que', 5), ('raimundo', 1), ('teresa', 1)]]

Usando os índices da lista para facilitar na classificação de cada palavra do texto, é reescrito utilizando identificadores numéricos, como demonstrado a seguir:

Texto 1: [[(0, 2), (1, 2), (2, 2), (3, 2), (4, 3), (5, 3), (6, 3)]]

Texto 2: [[(0, 6), (1, 1), (2, 1), (3, 1), (4, 1), (5, 1), (6, 1), (7, 5), (8, 1), (9, 1)]]

Com base nas frases, monta-se o vetor de características, que é basicamente uma lista de todas as palavras contidas em ambos os textos, sem repetição:

['No' 'meio' 'do' 'caminho', 'tinha', 'uma', 'pedra', 'no', 'João', 'amava', 'Teresa', 'que', 'Raimundo', 'Maria', 'Joaquim', 'Lili', ' ', 'não', 'ninguém', '.']

Esta lista ajuda na redução da dimensionalidade através do processo de matriz de termo documento dos textos [71].

	w_1	w_2	w_3	...	w_n
d_1	1	0	0	...	1
d_2	0	0	1	...	1
d_3	1	1	0	...	0
$\vdots$					$\vdots$
d_m	0	0	1	...	0

Figura 7 - Exemplo de BoW. Elaborado por Oguri et al. Fonte: [71].

No modelo BoW qualquer texto ou frase, documento, coleções de documentos, são vistos como um grupo de elementos como demonstra a Fig. 7, consoante a utilização, estes elementos podem ser palavras simples como unigramas, bi-gramas, estruturas compostas, etc [31, 53].

Na Fig. 7, mostra que d_1 representa o documento 1 e w_1 , a ocorrência da primeira palavra naquele texto, os pesos são representados por números entre 1 e 0, estes indicam a ocorrência ou não de uma dada palavra em um determinado texto, sendo utilizados para extrair informações relativas à semelhança de textos a partir do número de palavras em comum [20]. Fundamentando as frequências em pesos, este pretendem estimar o número de ocorrências de uma dada palavra num determinado texto, servindo como base para medida TF-IDF [58, 66, 72].

Na Fig. 8 mostra uma visualização interna da matriz criada pelo modelo BoW usado pelo classificador proposto para o auxílio a RS nesta dissertação, onde é possível visualizar a frequência dos termos dentro do documento.

	0	1	2	3	4	5	6	7	8	9 ...
0	(adult, 2)	(adult_spinal_deformity, 1)	(adults, 9)	(affected, 4)	(age, 1)	(analysis, 4)	(assessment, 4)	(background, 1)	(balance, 2)	(capacity, 1) ...
1	(age, 1)	(compared, 2)	(conclusions, 1)	(degree, 1)	(health, 4)	(matched, 1)	(methods, 1)	(observed, 1)	(one, 1)	(patient, 2) ...
2	(age, 2)	(background, 1)	(data, 3)	(determined, 1)	(eighty, 1)	(every, 1)	(greater, 1)	(hundred, 2)	(improved, 1)	(methods, 1) ...
3	(age, 1)	(disease, 1)	(domain, 1)	(included, 1)	(methods, 1)	(outcome, 1)	(population, 1)	(results, 1)	(significant, 2)	(study, 3) ...
4	(age, 2)	(analysis, 2)	(conclusions, 1)	(data, 1)	(design, 1)	(general, 3)	(high, 1)	(included, 2)	(literature, 1)	(one, 1) ...

5 rows × 394 columns

Figura 8 - Amostra da BoW a ser utilizado na RS desta dissertação.

3.3.8. TF-IDF

A medida *TF-IDF* calcula a importância de uma palavra em um texto, baseando na frequência em que ela aparece em todo o conjunto de documentos. *TF-IDF* é considerada o modo de análise de texto mais comum usado para RS, tornando este recurso bastante utilizado junto com algoritmos de *machine learning* [48]. Essa medida considera que se uma palavra aparece várias vezes num único documento, então é considerada importante, ganhando uma pontuação alta. Contudo se muitos documentos contiverem esta palavra, então não deve ser usada como identificador, recebendo uma pontuação baixa [58].

Para efetuar o cálculo do *TF-IDF* este é separado em duas etapas: a primeira define a frequência dos termos *TF* [73, 76].

$$TF(t, d) = \frac{\text{número de vezes que o termo}(t) \text{ aparece no documento}(d)}{\text{número total de termos no documento}(d)} \quad (1)$$

Onde na equação 1 explica que $TF(t, d)$ corresponde à quantidade de vezes que a palavra t aparece no documento d . A segunda etapa apresenta a parte do inverso da frequência nos documentos $IDF(t)$.

$$IDF(t) = \ln \left(\frac{\text{Total de textos}}{\text{Quantidade de textos em que o termo } t \text{ aparece}} \right) \quad (2)$$

Na equação 2, pode-se observar que o inverso da frequência nos documentos é concedido pelo logaritmo do total de documentos ou textos no conjunto dividido pelo número de textos em que a palavra aparece. A pontuação que a palavra ganha é representada como peso de um termo [77,78].

Para um melhor entendimento do funcionamento da medida *TF-IDF* é mostrado um pequeno exemplo de como obter os resultados dos cálculos dos pesos. Suponha que um determinado documento incluindo 100 palavras onde a palavra "CDG" apareça três vezes. A periodicidade do termo (*TF*) é dada por $3 \div 100 = 0,03$. Reconhece que há 10 milhões de documentos e que a palavra CDG aparece em 1000 desses documentos. O inverso da frequência

nos documentos (*IDF*) é calculado como $\ln(10.000.000 \div 1.000) = 4$. Prontamente, o peso *TF-IDF* é o produto desses valores: $0,03 \times 4 = 0,12$.

3.4. Classificação automática de documentos

Em [79, 80] os autores demonstram que a classificação automática de documentos é um procedimento que se refere à construção de classificadores pelo uso de processos indutivos. Este processo indutivo chamado de aprendizagem, constrói um classificador para uma classe *C* observando as características de um conjunto de documentos anteriormente classificados sob a classe *C* por um investigador da área pretendida. Este tipo de aprendizagem é denominado de supervisionado, onde um documento novo é classificado de acordo com a comparação de um classificador produzido e treinado a partir de documentos rotulados (classificados).

Para o desenvolvimento do classificador, são utilizadas nesta dissertação duas ferramentas para este propósito: o SVM e LDA. Ambas serão utilizadas em conjunto, servindo o LDA a auxiliar o SVM quando há poucas informações atribuídas manualmente [42].

A entrada do tratamento da classificação é composta de várias coleções de dados, no caso dessa dissertação, textos representados algebricamente por um aparato de documentos *D* ou corpus, ficando no seguinte formato $D = \{d_1, d_2, \dots, d_i\}$, e as classes associadas a cada coleção de documentos da seguinte forma, $C = \{c_1, c_2, \dots, c_k\}$ [31, 77, 122].

A classificação consiste em determinar se o documento d_i pertence ou não a categoria de classe C_k , para $i = 1, 2, \dots, n$ e $k = 1, 2, \dots, z$, permanecendo estes representados como vetores (d_1, c_1) , ..., (d_i, c_k) , onde d_i são um vetor que representa os termos que ocorrem no texto e C_k é a classe associada ao documento, mantendo assim a seguinte relação representada pelo vetor de pré-processamento de textos: $D = \{(d_1, c_1), (d_2, c_2), (d_3, c_3) \dots (d_i, c_k)\}$ [20, 81, 82].

Segundo [31], a classificação de dados é constituída de duas classes, *single-label* e *multi-label*, estas servem para gerenciar em que estado está cada documento, estando a informação na classe *single-label* pertence a apenas uma classe, já no caso da *multi-label*, o mesmo texto ou documento pode pertencer ou estar associado a mais categorias de classes [20].




Figura 9 - Indução de classificador em aprendizagem supervisionada. Fonte: [123].

A Fig. 9 demonstra graficamente o que foi explicado, mas neste caso o conjunto D ou o corpus é representado por $x_1, x_2, \dots, x_n$, sendo estes os documentos, formando uma matriz onde pode ter as classes ou *label*, representadas por $y_1, y_2, \dots, y_n$, fornecendo informações para o classificador $f(x)$.

3.5. Algoritmos de Classificação

Neste capítulo será apresentado o classificador utilizado nesta dissertação e o modelo probabilístico empregado para identificar grupos de tópicos, que ajudará a obter conteúdo não classificado, evitando que se faça qualquer tipo de suposição forte sobre a relação entre o texto e as categorias utilizando apenas a distribuição de palavras para os tópicos.

3.5.1. SVM

SVM é um modelo versátil de classificador, capaz de fazer classificações lineares e não lineares, de regressão até mesmo detecção de *outliers*. Este modelo foi desenvolvido pelo russo Vladimir Vapnik, tendo em sua base a teoria da aprendizagem estatística, a qual está fundamentada nos erros da técnica de aprendizagem junto aos dados de validação ou erro de generalização, ficando limitado pelo erro de treinamento [83, 123].

A técnica SVM é utilizada nesta dissertação para realização de tarefas de categorização de textos, oferecendo de forma automática uma ou mais categorias predefinidas a documentos textuais. Mas a SVM pode ser empregada também em reconhecimento de caracteres, como sistema de reconhecimento de assinatura, bioinformática, auxiliando na compreensão de estruturas genéticas, classificação de e-mails, ajudando na toma de decisão entre um e-mail bom e um *spam*, entre outras utilidades[124, 125].

O funcionamento da SVM usa o conceito de classificação supervisionada, o objetivo é fazer com que a máquina seja capaz de classificar os objetos ou no caso desta dissertação os

textos rotulados em classes distintas, a partir de exemplos anteriores, sendo capaz de fazer a classificação de novas entradas (novos textos) a classe que vai pertencer. A técnica SVM possibilita duas formas de ser aplicada: o uso em informações que estejam em modo linear, sendo possível serem separados por um hiperplano (SVM Linear) e a forma SVM Não Linear, onde as informações estão em um padrão que não podem ser separados por um hiperplano. Este tipo de SVM Não Linear, mapeia o conjunto de treinamento que está dentro do seu espaço original, para um espaço de dimensões maiores, conhecido como espaço de características (*features space*) [138, 140]. Na Fig. 10 (a) apresenta um conjunto de treinamento, não possuindo dados não lineares, e a Fig. 10 (b) exibe o conjunto de treinamento num espaço de dimensões maiores. Para esta dissertação será empregado o classificador SVM Linear [38, 123]




Figura 10 - Exemplo de SVM não linear com como espaço de características. Fonte:[139, 140]

A ideia do classificador SVM é simples de interpretar: no processo de treinamento contendo os dados rotulados, o classificador SVM examina os dados de entrada que identifica padrões em dois semi-espacos correspondentes às duas classes, estando o hiperplano a separar estes espacos. Todos os dados de entrada são representados como pontos nesse espaco e são mapeados para as categorias de saída de forma que as categorias sejam divididas pela maior e mais clara lacuna possível. Na Fig. 11 pode-se constatar o que foi exemplificado acima [42, 48, 83, 123, 127].




Figura 11 - Representação do hiperplano gerado pelo classificador SVM e suas margens.

O hiperplano é determinado como uma função de mapeamento $y = f(x)$, entre um vetor de característica multidimensional x e uma grandeza ou um conjunto desta em y . Para produzir o mapeamento, a única informação disponível é o conjunto de treino, concebido $D = (x_i, y_i) \in X \times Y, i = 1, \dots, l$, com l sendo o número de pares (x_i, y_i) da amostra [38, 140].

A equação do hiperplano em $\mathbb{R}^d$, é:

$$f(x) = wx + b = 0 \quad (3)$$

onde na equação (3):

w : é o vetor que representa o conjunto de entradas, conhecido como vetor de peso (*weight vector*);

x : são os pontos sobre o hiperplano;

b : é a distância entre o hiperplano e o ponto de origem.

A partir da equação (3) o hiperplano poderá separar os dados em duas regiões, sendo elas: para $f(x) > 0$ ou $f(x) < 0$ [131, 132, 140], podendo ser utilizado a função de sinal, conforme pode ser observado na equação (4).

$$h(x) = \text{sgn}(f(x)) = \begin{cases} -1 & \text{se } w \cdot x + b < 0 \\ +1 & \text{se } w \cdot x + b > 0 \end{cases} \quad (4)$$

Sendo que o $+1$ e o -1 representam as respectivas classes. Com a possibilidade de poder obter diversos hiperplanos, pode-se deduzir que o melhor hiperplano para separar as classes é o que possui a maior margem entre as classes, sendo este chamado de hiperplano ótimo. A margem é definida como duas vezes a distância do hiperplano (reta) até o dado mais próximo, neste caso, pode-se deduzir que, se obtiver uma margem com uma distância grande entre as classes, então menor será o erro associado à classificação de novos dados de entradas [132].

Para o melhor hiperplano é preciso definir os vetores de suporte (*support vector*) que são os dados de ambas as classes, os quais estão próximo do separador de classes (hiperplano ótimo, veja Fig. 11) [133].

A Fig. 11 mostra os vetores de suporte com suas margens, este vetor pode ser representado pela equação (5):

$$|w \cdot x_i + b| = 1; \quad i = 1, 2, \dots, n. \quad (5)$$

Onde na equação (5):

i : posição do objeto;

n : quantidade de objetos existentes no conjunto;

x_i : corresponde a um determinado dado;

Esta equação (5) satisfaz as seguintes restrições:

$$\begin{cases} w \cdot x_i + b \geq +1 & \text{se } y_i = +1 \\ w \cdot x_i + b \leq -1 & \text{se } y_i = -1 \end{cases} \quad i = 1, 2, \dots, n.. \quad (6)$$

Onde:

$y_i: y_i \in \{-1, +1\}$, estes valores representam o valor de classificação de x_i , definindo se o dado está na parte maior que zero ou na parte menor que zero do classificador. A equação (6) pode ser resumida na equação (7):

$$y_i (w \cdot x_i + b) - 1 \geq 0; \quad i = 1, 2, \dots, n.. \quad (7)$$

$$\text{Referindo-se as restrições de } y_i (w \cdot x_i + b) - 1 \geq 0, \forall i = 1, \dots, n. \quad (8)$$

O hiperplano ótimo é encontrado através da maximização da margem. Essa maximização da margem é obtida pela minimização ou redução de $\|w\|$, veja a equação (9)[131]:

$$\text{Minimizar}_{w,b} \frac{1}{2} \|w\|^2 \quad (9)$$

onde:

$$\|w\|: \text{ é a norma euclidiana de } w, \|w\| = \sqrt{w * w}.$$

Deste modo, pode-se garantir que não haverá nenhum dado entre as margens, esta é a caracterização do SVM Linear com margens rígidas. Para poder resolver o problema da minimização de $\|w\|$, respeitando as restrições da equação (9), é usado o método de multiplicadores de *Lagrange* [134], fornecendo o máximo e o mínimo de uma função sujeita a uma restrição.

$$L(w, b, \lambda) = \frac{1}{2} \|w\|^2 - \sum_i \lambda_i (y_i (w \cdot x_i + b)) - 1 \quad (10)$$

onde:

λ_i : são os multiplicadores de *Lagrange*.

Para uma ótima solução, se faz necessário minimizar a função de *Lagrange*, maximizando os multiplicadores de *Lagrange* (λ), e minimizando o w e o b [135] obteve-se o seguinte problema de otimização:

$$\text{Maximizar}_{\lambda_i} \sum_{i=1}^n \lambda_i - \frac{1}{2} (w \times x_i + b) \quad (11)$$

$$\text{Com as restrições: } \begin{cases} \lambda_i, \geq 0, \forall i = 1, \dots, n \\ b = 0 \end{cases} \quad (12)$$

onde:

$$w = \sum_{i=1}^n \lambda_i x_i y_i \quad \text{e} \quad b = \sum_{i=1}^n \lambda_i y_i \quad (13)$$

O problema de otimizar, visto na equação (13), é que possui um único máximo global[137] que pode ser encontrado, podendo ser expresso na equação (14):

$$h(x) = \text{sgn} \left(\sum \lambda_i y_i (x_i x) + b \right) \quad (14)$$

Com a função λ_i diferente de zero, estes são os dados chamados de vetores de suporte, sendo os pontos mais próximo do hiperplano, e para os demais dados $\lambda_i = 0$ [136]. Deste modo a função classificadora é:

$$f(x) = \sum \lambda_i y_i x_i x + b \quad (15)$$

Comprovando que o que o hiperplano obtido pelas equações explicadas, é habilitado a classificar os dados que estejam dentro do parâmetro da equação (3), demonstrando que esses dados são linearmente separáveis [137, 140].

3.5.2. LDA

A alocação de Dirichlet latente ou em inglês *latent dirichlet allocation* mais conhecido como LDA, é um modelo probabilístico de tópicos usado para processamento de NLP e extração de tópicos com base em conteúdo, que liga a categoria de aprendizagem de texto não classificado. A modelagem de tópicos é representada como uma distribuição sobre palavras, sua base está vinculada ao classificador *Naive Bayes* sendo este um classificador probabilístico. Esta técnica (LDA) nasceu da necessidade da extração de informações em textos em meados do ano de 2003, para fazer modelagem de tópicos com base na probabilidade e sendo nos dias de hoje uma das técnicas mais populares [39, 40, 54].

Para a identificação de tópicos, o modelo LDA utiliza de métodos de agrupamento na identificação de grupos de artigos significativo. Em [39] os autores mostram que o modelo de tópicos aparece apenas durante o seu processamento (chamado de latente). O LDA não é um classificador por si, porém usa uma abordagem de geração de tópicos, sendo muito utilizado para evitar qualquer suposição forte sobre a relação do texto e as categorias, usando as distribuições de palavras para os tópicos de modelo matemático. O LDA não precisa ter rótulos de classes conhecidas como em alguns tipos de classificadores supervisionado onde faz

deduções de padrões. Esse processo todo é descrito através de modelos probabilístico e estatístico para identificar grupos de tópicos.

As explorações de grandes volumes de dados com poucas informações atribuídas em descobertas de tópicos são demonstradas em [39, 42] onde estruturas com valores semânticos e que no contexto de *text mining* formam grupos de termos que frequentemente ocorrem juntos. Quando analisadas dão indícios a um tema ou assunto, ocorrendo em subconjuntos de documentos. O termo tópico é definido como um conjunto de palavras que possuem relacionamentos dentro daquele documento ou texto extraídos automaticamente.

Para poder entender melhor o funcionamento do modelo probabilístico, suponha que foi fornecido um *corpus* contendo revisões de artigos que inclui vários textos. Os textos das revisões que foram enviadas por revisores ao longo do tempo contêm muitos termos, alguns dos quais são usados em vários tópicos. Um tópico que é identificado pelo método probabilístico LDA pode representar revisões para um artigo individual ou pode representar um grupo de revisões de artigos. Para o LDA, o tópico em si é apenas uma distribuição de probabilidade ao longo do tempo para um conjunto de termos [84, 85].

Os termos raramente são exclusivos para qualquer texto, mas podem consultar outros textos ou ser termos gerais que se aplicam a tudo, exemplo seria: "bom", "maravilhoso", "feliz", "tristeza". Outros termos podem ser palavras corrompidas, sem sentido, palavras com caracteres desnecessários sendo chamado de ruído. No entanto, é importante entender que o método LDA não tem o propósito de capturar todas as palavras contidas no *corpus* ou entender como as palavras estão relacionadas, além das probabilidades de concorrência. Ele só pode agrupar palavras que foram usadas no domínio de destino.

Após os índices de termos serem computados, linhas individuais de texto são comparadas usando uma medida de similaridade baseada em distância, para determinar se duas partes do texto são semelhantes. Por exemplo, pode-se achar que o artigo tem vários nomes que estão fortemente associados ou provavelmente se acham que termos fortemente negativos geralmente são associados a um artigo específico. Pode-se usar a medida de similaridade para identificar termos relacionados e para criar recomendações [39,40].

Matematicamente a modelagem LDA tem em sua base a distribuição de *dirichlet*, denotada por $Dir(z, \alpha)$, e segundo [18]:

$$Dir(z, \alpha) = \frac{1}{B(\alpha)} \prod_{k=1}^K z_k^{\alpha_k - 1} \quad (16)$$

Onde $z = (z_1, z_2, \dots, z_k)$ é uma variável K dimensionada, entre os valores $0 \leq z \leq 1$ $[0,1]$ e $\sum_{i=1}^K z_i = 1$. Neste contexto $\alpha = (\alpha_1, \dots, \alpha_k)$ são os hiper-parâmetros da distribuição. A função $B(\alpha)$, chamada de função Beta, na qual pode ser expressa em termos da função gama Γ

$$B(\alpha) = \frac{\prod_{k=1}^K \Gamma(\alpha_k)}{\Gamma(\sum_{k=1}^K \alpha_k)} \quad (17)$$

O LDA não utiliza as semânticas usadas por humanos, sendo estas acessadas pelos algoritmos através das técnicas de BoW pela qual as ordens das palavras são ignoradas [50].

A amostra da distribuição de tópicos é feita pela distribuição *dirichlet* que é a generalização multivariada da distribuição Beta, usado para alocar as palavras de diferentes tópicos que preencherão os documentos, podendo dar indícios de que a intenção desse modelo de algoritmo é alocar os tópicos latentes que são distribuídos, obedecendo a distribuição de *dirichlet*, essa por sua vez é uma distribuição discreta multivariada [39, 86].

Na Fig. 12 é representado de forma gráfica a rede Bayesiana, nesta rede, cada vértice condiz a uma variável, e a aresta à relação de dependência. Nesta representação, em vez de demonstrar cada variável repetidas vezes, um retângulo é usado para agrupar variáveis em um subgrafo que se repete. O número de repetições é rotulado na parte inferior de cada retângulo




Figura 12 - Modelo gráfico da distribuição Dirichlet, Adaptada da Fonte: [39]

O LDA, contém três níveis hierárquicos, sendo fortemente influenciado pelo modelo Bayesiano como pode-se constatar na Fig. 12. Na primeira etapa, há representação da distribuição de tópicos em toda a coleção de documentos, na segunda etapa de níveis, inclui a distribuição dos tópicos para cada documento. No último nível, repete-se a distribuição dos tópicos internamente para as palavras em um documento. Com o último nível, tona-se possível representar um documento como uma mistura de tópicos [129].

A Fig. 12 pode ser melhor descrita através da seguinte legenda para suas variáveis [39]:

- n - número de palavras do vocabulário.
- m - número de documentos.
- K - Número de tópicos
- n_{d_j} - número de palavras em um documento d_j , onde $1 \leq j \leq m$.
- θ - distribuição de tópicos por documentos.
- φ - distribuição dos tópicos sobre as palavras do vocabulário.
- θ_j - vetor com a proporção dos tópicos para o documento d_j , onde $1 \leq j \leq m$.
- φ_k - vetor com a proporção das palavras do vocabulário para o tópico k , onde $1 \leq k \leq K$.
- α - Priore da distribuição de Dirichlet, relacionada a distribuição documento-termo.
- β - Priore da distribuição de Dirichlet, relacionada a distribuição tópico-palavra.
- w_i - i -ésima palavra do vocabulário, onde $1 \leq i \leq n$.
- $w_{j,i}$ - palavra w_i observada no documento d_j , onde $1 \leq j \leq m$ e $1 \leq i \leq n$.
- $z_{j,i}$ distribuição de tópicos associado a palavra $w_{j,i}$ no documento d_j , onde $1 \leq j \leq m$ e $1 \leq i \leq n$.

Observando a Fig. 12, percebe-se que os hiper-parâmetros representados por α e β , influenciam no nível de coleções de documentos. Se na modelagem do LDA o valor de α for alto, significa que cada documento provavelmente conterá uma maior mistura de tópicos e o mesmo parâmetro, se o α for baixo, eventualmente o modelo de LDA terá uma mistura de poucos tópicos, ocasionando uma maior concentração nesses tópicos. Um alto valor do parâmetro β calcula a probabilidade de cada tópico conter uma mistura de várias palavras, sendo

que ao contrário, β com valor baixo, indica tópicos formados com poucas palavras, oferecendo um modelo fraco de tópicos [39, 129]. Em capítulos posteriores será apresentado a implementação do modelo LDA pela biblioteca *Gensim* junto com o de gráficos de bolhas que a biblioteca disponibiliza.

3.5.3. Medidas de desempenho para o algoritmo de classificação

Para um bom funcionamento do algoritmo de apoio a RS são utilizados alguns métodos para dar maior exatidão na classificação, fazendo a validação se o classificador está a executar seu serviço corretamente. Para a classificação dos textos em “relevante” ou “não relevante” é necessário utilizar de medidas específicas e técnicas como validação cruzada para obter bons resultados. Quando se trata de classificação supervisionada, se faz necessário utilizar medidas chamadas de métricas que verificam se o classificador está apto a caracterizar novos exemplos quando lhe é apresentado.

A métrica de avaliação na maioria dos casos, utiliza-se de uma matriz quando se trata de classificação supervisionada e binária, com amostras classificadas corretamente e incorretamente, denominada de matriz de confusão, que é uma tabela frequentemente usada para descrever o desempenho de um modelo de classificação em um conjunto de dados [38, 86].

A ideia geral da matriz de confusão é averiguar o número de vezes que a classe “relevantes” é classificada como “não relevantes” e para chegar a essa conclusão, a matriz de confusão utiliza-se de um conjunto de previsões para que possam ser comparadas com os valores reais. Esse conjunto de previsão pode ser descrito como:

<u>Classe correta</u>	<u>Positiva</u>	<u>Negativa</u>
Positiva	Verdadeiras Positivas (TP)	Falsas Negativas (FN)
Negativa	Falsas Positivas (FP)	Verdadeiras Negativas (TN)

Tabela 1 - Métricas utilizadas para a classificação supervisionada.

Sendo descrito com maiores detalhes abaixo:

- TP (Verdadeiro Positivo) = número de artigos da classe “relevantes”, classificados como artigos da classe “relevantes”.

- FN (falso negativo) = número de artigos da classe “relevantes”, classificados como artigos da classe “não relevantes”.
- TN (Verdadeiro Negativo) = número de artigos da classe “não relevantes”, classificados como artigos da classe “não relevantes”.
- FP (Falso Positivo) = número de artigos da classe “não relevantes”, classificados como artigos da classe “relevantes”.

		<i>Valores preditos</i>	
		Relevantes	Não relevantes
<i>Valores reais</i>	Relevantes	TP	FP
	Não relevantes	FN	TN

Tabela 2 - Matriz de Confusão mostrando as categorias.

Onde pode-se constatar com maior precisão a explicação das seguintes métricas:

$$FP = N - TP \quad (18)$$

Em que número N é o número de “relevante”, do tipo classe “relevante”.

$$FN = M - TN \quad (19)$$

Em que número M é o número de “não relevante”, do tipo classe “relevante” [54]. A matriz de confusão fornece muitas informações que podem causar um mal entendimento na hora de explorar os resultados, para este tipo de problema pode ser resolvido com uso das métricas, como o uso da *acurácia, precisão, renovação, F1 (pontuação, recall)* do classificador, sendo explicado como a razão entre o número de exemplos positivos corretamente classificados e o número total de exemplos identificados como positivos pelo classificador [38, 54, 86].

$$precisão = \frac{TP}{TP + FP} \quad (20)$$

A precisão produz a percentagem de artigos que foram classificados pelo modelo, como sendo da classe “relevante”, dando relevância a informações da classe positiva (TP), logo quanto maior a precisão menor será o esforço realizado para analisar os artigos da classe “relevante” [38].

A desvantagem dessa medida é que ela não leva em consideração os artigos de classe “não relevante”. Segundo os autores de [84, 86], a maneira perfeita de ter uma precisão seria fazer uma única previsão positiva e garantir que ela seja correta (*precisão* = $1/1 = 100\%$), não sendo muito útil para a investigação, levando o classificador a ignorar todas as partes “não relevante” e menos a “relevante”. Deste ponto de vista, a precisão é utilizada em conjunto com outra métrica levando o nome de *renovação*, ou tem as seguintes designações de *sensibilidade* ou *taxa de verdadeiro positivo (TPR)*, onde esta representa a proporção de verdadeiros positivos que foram corretamente identificados.

$$\text{renovação, recall ou TPR} = \frac{TP}{TP + FN} \quad (21)$$

Para a percentagem de acertos do classificador, é utilizado a *acurácia* que considera o número de acertos sobre as amostras positivas e negativas, essa medida visa todo o objetivo do trabalho de classificação, aproximando-se assim mais da capacidade humana de avaliar a subjetividade de um texto corretamente [54, 87, 88].

$$\text{acurácia} = \frac{TP + TN}{TP + TN + FP + FN} \quad (22)$$

Em algumas circunstâncias, é necessário ter uma métrica que indique a qualidade geral do seu modelo de classificação supervisionada, que trabalhe bem até com conjuntos de dados que possuem classes desproporcionais. Essa métrica combina precisão e renovação, sendo chamada de *F1*, sendo uma média harmônica de precisão e renovação, enquanto a média regular trata igualmente todos os valores. A média harmônica dá mais peso aos valores mais baixos, resultando em pontuações *F1* altas se a renovação e a precisão forem altas também. Em um pequeno resumo segundo o autor de [38], *F1* é uma métrica melhor que a acurácia principalmente em casos onde falsos positivos e falsos negativos possuem impactos diferentes para seu modelo, sendo que *F1* cria um resultado a partir dessas divergências.

$$F1 = \frac{2 * \text{precisão} * \text{renovação}}{\text{precisão} + \text{renovação}} \quad (23)$$

Além das métricas de classificação supervisionada, também é utilizado para esta dissertação as medidas de avaliação para o modelo probabilístico, como a perplexidade de log do modelo e a coerência dos tópicos. Estas medidas fornecem uma conveniência para julgar quanto é bom um determinado modelo de tópico.

A perplexidade de log mede as restrições expressas pelo modelo, do ponto de vista da tarefa de reconhecimento pode-se dizer que o modelo de linguagem reduz o número de opções de palavras durante o processo de reconhecimento, fazendo com que seja interpretada como o número médio de opções de palavras. A perplexidade mede a dificuldade de tarefa de reconhecimento: quanto menor a perplexidade de log, menor a taxa de erro [89].

$$2^{H(p)} = 2^{-\sum_x p(x) \log_2 p(x)} \quad (24)$$

Em que:

- $H(p)$: é a entropia (em bits) da distribuição
- p : Probabilidade discreta
- x : é uma variável sobre os eventos

Nota: Entropia neste caso da perplexidade de log, está vinculada a área da Teoria da Informação, sendo definida como uma forma de determinar o grau médio de incerteza em relação as fontes de informação [90].

A coerência dos tópicos é uma medição da qualidade de propriedade do tópico, que permite que se construa sentido a partir dele, estabelecendo relação entre suas partes e entre o próprio texto a que pertence e a situação de sua ocorrência. Em outro contexto, a coerência pode ser vista como a medida da correlação entre as fases de cada tópico em diferentes pontos de um texto. A coerência de tópicos pode ser dividida nos seguintes segmentos [91, 92]:

- Segmentação: onde os tópicos são divididos em vários parâmetros, assumindo que as qualidades dos tópicos em cada parâmetro são diferentes.
- Estimativa de probabilidade: onde é medida a quantidade de tópicos em cada parâmetro.
- Medida de confirmação: onde a qualidade do tópico (de acordo com uma determinada métrica) em cada parâmetro é medida e um número é atribuído.
- Agregação: o medidor em que esses números de qualidade são combinados de uma certa maneira (média aritmética) para criar um número.




Figura 13 - Função onde pode-se constatar o desenvolvimento da coerência de tópicos Fonte: [91].

Onde pode ser descrito segundo Fig. 13:

- t : tópicos provenientes do modelo de tópico
- S : tópicos segmentados
- P : Probabilidades calculadas
- Vetor phi ($\vec{\phi}$: um vetor das "medidas confirmadas" saindo do módulo de confirmação
- C : o valor final da coerência

3.6. Técnica de balanceamento

Para o equilíbrio das informações contidas no conjunto de dados, pode-se utilizar diversas técnicas de balanceamento, sendo as mais comuns: *random undersampling* e *random oversampling*. Para o propósito desta dissertação foi adotada o uso da técnica *random oversampling*, mais adequada para natureza do *corpus* escolhido.

O procedimento *random undersampling* é uma técnica que reduz aleatoriamente as amostras majoritárias e iguala a quantidade das minoritárias. A ideia é que os dados da classe dominante possuem registos redundantes, sendo que uma quantidade de dados menores e equilibrados trazem benefícios ao desempenho do modelo, facilitando a sua exploração. A desvantagem é que pode haver perdas de informações importantes à classe majoritária [54].

Já a técnica *random oversampling* é o contrário da *random undersampling*. A *random oversampling* replica aleatoriamente a classe minoritária até igualar a classe majoritária ou ser suficiente para o balanceamento dos dados. Esta escolha baseia-se no conjunto de informações que há no *corpus*, sendo um conjunto relativamente pequeno, com classes raras contendo

algumas dezenas de registros (artigos). Veja na Fig. 14 como estas duas técnicas são exemplificadas visualmente [54].



Figura 14 - Exemplo de técnica Oversampling e Undersampling.

A técnica de reamostragem *random oversampling* leva em conta o peso (p) de cada amostra da classe minoritária, tendo $p = 1$, dado pelo algoritmo de reamostragem que terá na função de perda. A função de perda é a otimização do critério de classificação e regressão, utilizada pelo algoritmo de reamostragem *oversampling* [54], este pondera a função de um jeito a descontar erros para registros com pesos baixos em favor de registros com pesos maiores. Muitos algoritmos de classificação assumem um argumento de pesos que nos permitem ponderar os registros acima/abaixo. O peso (p) para a classe majoritária é definido como $\frac{1}{p}$, fazendo com que a classe minoritária seja aumentada para igualar a proporção da majoritária, no final a soma total dos pesos é praticamente a mesma [54, 93, 94].

A vantagem de utilizar a reamostragem *random oversampling* é que não se perde informações, mas pode haver questões sobre ajuste conhecido como *overfitting* dos dados, pois esta multiplicação ou replicação mostra-se ineficaz para prever novos resultados [94].

3.7. Sumarização de artigos

O processo de transcrever um texto em uma versão menor, é chamado de sumarização de texto, podendo ser de dois tipos: extrativa e abstrativa. Na primeira são produzidos conjuntos de frases importantes de um documento sem alterações, já na segunda, há um processo de melhoria da coerência do texto, eliminando redundâncias, deixando as frases mais concisas, vindo a criar novas orações [96].

No processo de sumarização, a redução da quantidade de texto em um documento, porém mantendo seus significados-chave, é imensamente útil para tentar descobrir se um

documento extenso atende ou não às necessidades do leitor e se vale a pena ler o restante daquelas informações. Com textos extensos, o algoritmo de sumarização processa e resume o documento no tempo que o leitor levaria para ler o primeiro parágrafo. O principal ponto chave é reduzir o tamanho e o detalhamento de um documento, mantendo os pontos principais e o significado geral [96, 97].

Nesta dissertação é utilizado a sumarização baseada no tipo extrativa, sendo seu ponto chave de resumo nos artigos a parte do *abstract*. Esta ação foi adotada pela seguinte razão, sendo o *abstract* uma parte do artigo que já demonstra um resumo do que se deseja mostrar, a sumarização em cima desta parte, calha bem em artigos onde há *abstract* extenso, em muitas das circunstâncias confundindo o leitor com a introdução do artigo.

Visando facilitar a parte da triagem dos revisores humanos na redução do fardo da leitura, foi investigado nesta dissertação a sumarização baseada neste aspeto, utilizando para isto a biblioteca *Gensim*, onde tem em seu alicerce fileiras de frases de textos, aplicando uma variação do algoritmo TextRank [98].

Também é empregado o reconhecimento das entidades de cada sumarização dos *abstracts*, utilizando a biblioteca *Spacy* para esta finalidade em conjunto com sua função *displacy*. Em [99] demonstra que as Entidades Nomeadas (EN) tem como representação um ou mais designadores rígidos num determinado texto. Alguns dos tipos de EN mais comuns são: substantivos próprios, tais como nomes de pessoas, organizações e entidades locais; entidades temporais como datas, tempo, dia, ano e mês; entidades numéricas, tais como medições, percentagens e valores monetários [99].

O método TextRank é um algoritmo não supervisionado de uso geral na área de sumarização, projetado para tarefas específicas de NLP, a ideia principal é a ordenação do texto baseada em grafos, tendo seu conceito fundamentado na matemática, num subcampo da teoria dos grafos [100, 101, 102, 103].

O algoritmo TextRank tem em sua base o algoritmo PageRank, outro algoritmo utilizado para fazer processos de buscas de posicionamentos de *websites*, sendo muito empregado pelo motor de busca do *Google*. Este algoritmo extrai frases-chave explorando a estrutura do respetivo texto, para determinar frases-chave que parecem essenciais para o texto, da mesma maneira que o PageRank[104].

Para poder entender melhor o algoritmo de TextRank, faz-se necessário uma pequena explanação da estrutura em termos matemáticos [105]:

$$C(N_i) = (1 - d) + d \sum_{N_j \in E_n(N_i)} \frac{p_{ji}}{\sum_{N_k \in S_a(N_j)} p_{jk}} C(N_j) \quad (25)$$

Onde segundo algumas anotações, pode-se constatar:

- $C(N_i)$: Classificação dos nós.
- N_i : nó
- d : d é um fator de amortecimento que visa incluir no modelo a probabilidade de salto aleatório de um nó do gráfico para qualquer outro.
- N_j : nós pertencentes ao conjunto $E_n(N_i)$
- N_k : nós pertencentes ao conjunto $S_a(N_j)$, estes são o total de nós que cada nó N_j recomenda
- p_{jk} : peso das recomendações.

Como é explicado em [80], a equação 18 demonstra um modelo de grafo ao qual pode ser definido como $G = (N, A)$, como sendo os parâmetros de um grafo direcional e pesado, ou seja, ele atribui pesos as recomendações de cada conjunto de nós. N é o conjunto de nós e A são as arestas, em que A é um subconjunto de $N \times N$. Sendo o nó N_i representado pelo conjunto $E_n(N_i)$, estes apontam para si mesmo, fazendo uma auto referência.

$C(N_j)$ é o conjunto de classificação de cada um dos nós N_j pertencente ao conjunto $E_n(N_i)$ ou seja, os nós que recomendam N_i , estando p_{ji} como pesos agregados as indicações. N_k , representa os nós pertencentes ao conjunto $S_a(N_j)$, estes são o total de nós que cada nó N_j recomenda, estando os pesos dessas recomendações representados por p_{jk} [100].

Na equação (18) um fator importante a se perceber é a variável d , um item que ajuda a amortizar o modelo na parte probabilística quando há um salto aleatório de um vértice do grafo a qualquer outro. Em uma situação usual ao navegar na Internet, esse fator representa a probabilidade do utilizador ascender uma página por meio de um *link*, localizado na página atual, sendo $(1 - d)$ a probabilidade de o utilizador saltar para a próxima página aleatoriamente não vinculada à página de origem. Pela documentação do TextRank, a definição original do fator d é de 0.85 estando entre os limites de 0 e 1.

Deste modo, o algoritmo de TextRank é independente de treinamento, que se constata na classificação supervisionada, sendo executado em qualquer parte aleatória do texto, determinando surgimentos de textos intrínsecos, oriundos da simples base das propriedades do texto a ser analisado, tornando-se um algoritmo bastante maleável na utilização de novos domínios e idiomas[104].

4. Apresentação e discussão de resultados

Neste capítulo será apresentado o desenvolvimento do classificador para aprendizagem automática em revisão sistemática de literatura, dando uma abordagem técnica em cima do uso das metodologias de programação, assim como os detalhes da constituição do *corpus* e suas dificuldades para se fazer a classificação em cima deste, bem como a utilização das métricas para esse tema em discussão.

4.1. Organização e balanceamento do *corpus*

O *corpus* deste trabalho é composto por uma coleção de artigos baseado nas investigações feitas em cima da base de dados do mecanismo de busca do PubMed, formando uma lista em linguagem Python 3. No *corpus* são constatadas quatro posições subdivididas em; índice na posição zero, a classificação do artigo na posição um, o título na posição dois e por último o *abstract* na posição três.

Índice [0]	Classificação [1]	Título[2]	<i>Abstract</i> [3]
------------	-------------------	-----------	---------------------

Tabela 3 - Organização de campo do corpus na lista.

Considerando a metodologia de classificação em que os artigos foram avaliados na categoria de “relevante” e “não relevante”, o conjunto de artigos classificados como já referido na seção 3.1, não está balanceado, contendo mais classificações “não relevante” do que “relevante”, causando assim um desequilíbrio nos resultados da classificação. Para o balanceamento deste *corpus*, fez-se necessário alguns ajustes na sua estrutura, como converter a base de informação em formato do tipo lista para um formato mais maleável para o classificador, exemplo o formato *dataframe* da biblioteca Pandas, antes de passar pelo processamento de texto efetuado pelas técnicas de *text mining*. Deixando as informações mais acessíveis aos procedimentos utilizados pelo classificador.

O *corpus* utilizado nesta dissertação é composto de dois ficheiros, um contendo os artigos selecionados e classificados pela equipa de triagem, arquivados em um ficheiro de folha de cálculo, como se pode observar na Fig. 15, com uma legenda descrevendo “Ficheiro .xlsx contendo artigos classificados”. E o segundo ficheiro contendo artigos diversos do campo da

Biomedicina, mas sem classificação sendo mostrado na Fig. 15 com uma legenda descrevendo “Ficheiro .dat contendo artigos não classificados”, sendo este um ficheiro oriundo do *script* desenvolvido em Python 3 para acessar a base de dados do PubMed, conforme descrito na seção 3.2.




Figura 15 - Visualização dos ficheiros que compõem o corpus.

O ficheiro contendo os artigos classificados é aberto, sendo processado para retirada do seu conteúdo, para verificar se estes dados contêm algum tipo de lixo, como valores nulos ou mesmo caracteres de interrogação utilizado pelos revisores para informar que há uma indecisão sobre a classificação de um determinado artigo. Com este processo concluído cria-se duas listas, a primeira contendo a classificação e a segunda lista os índices de cada artigo, sendo possível organizar o conteúdo através do pareamento dos elementos contidos em ambas as listas, como pode ser constatado na Fig. 16.

```
#####Leia os dados de classificação (os conjuntos de treinamento, validação e teste) #####
os.chdir(os.path.dirname(patchExcel))
df = pd.read_excel('ArticleSelection_Sample_CP_RF_SB.xlsx', 'Indexes', index_col=None, header=None)

df2      = df[df[1].notnull()] # Busca se há valores nulos em alguma coluna
isnotqm  = df2[1]!='?'        # Busca se há caracteres de '?' utilizado para informar indecisão na classificação
df3      = df2[isnotqm]
listinds = df3[0].tolist()    # Definindo lista para conter valores de índice
listclasses = df3[9].tolist() # Definindo lista para conter valores de classificação

del listinds[0]
del listclasses[0]
indsAndClasses = zip(listinds,listclasses) # Juntando os campos contendo os índices de cada artigo e sua classificação
```

Figura 16 - Ficheiro .xlsx sendo processado para retirada de conteúdos irrelevantes.

Seguindo com o desenvolvimento, é aberto o segundo ficheiro contendo os artigos não classificados. Com isto é possível unir os dois ficheiros em uma única lista, sendo selecionados os campos através de uma estrutura algorítmica para poder separar os artigos classificados dos não classificados em uma nova lista que contem índice, título e *abstract* como mostrado na Fig. 17.

```
os.chdir(os.path.dirname(patchDAT))
with open("records.dat", "rb") as fp: # Unpickling
    records = pickle.load(fp)

"""Formando o corpus contendo
os artigos classificados"""
data = [[ic[0],ic[1],records[ic[0]]['TI'],records[ic[0]]['AB']] for ic in indsAndClasses]
```

Figura 17 - Estrutura de repetição para organização da nova lista Python (corpus).

```

[[138, índice dado pelos revisores
1, Classificação do artigo
'Studies in the modified Scoliosis Research Society Outcomes Instrument in adults: validation, reliability, and discriminat
ory capacity.', Título do artigo
"STUDY DESIGN: Observational study of patients with scoliosis and matched controls. OBJECTIVES: To determine the validity a
nd reliability of the modified Scoliosis Research Society Outcomes Instrument (SRS-22) for use in the assessment of deformity
in adults. To demonstrate the discriminate validity of the SRS-22 in differentiating between affected and unaffected adults.
SUMMARY OF BACKGROUND DATA: Spinal deformity has an important impact on the general health status of adults. The magnitude of
this impact has been difficult to measure and reported variably in the literature. The development of disease-specific outcom
es tools permits improved sensitivity and specificity in measuring the patient's self-assessment of health status. An instrum
ent for measuring disease-specific health status in adults with scoliosis has not been validated. MATERIALS AND METHODS: Obse
rvational study comparing the health status of adults affected by scoliosis and unaffected controls, matched for age, gender,
and socioeconomic status. Pearson correlation analysis was used to determine the relationship of each domain within the SRS-2
2 and SF-36 with radiographic parameters including sagittal balance, coronal balance, and major curve correction. Discriminat
e validity of the modified SRS instrument was determined by a comparison of means between affected and unaffected cohorts. Th
e validation of the SRS-22 was determined by criterion validity, using correlation analysis with comparable domains of the SF
-36. The reliability of the SRS-22 was demonstrated using test-retest parity and Cronbach's alpha test for internal consisten
cy. RESULTS: One hundred eighty adults were included in the study, 146 with scoliosis and 34 without. Adults with scoliosis s
cored significantly lower than unaffected controls on every domain of the SRS-22 and the SF-36. The floor and ceiling effect
of the SRS-22 was less than observed in the SF-36 instrument. Pearson correlation analysis demonstrated a significant correla

```

Figura 18 - Uma demonstração do conteúdo da lista que se forma com os dois ficheiros.

Com essa sequência de passos até o momento, tem-se uma lista como se pode constatar na Fig. 18, contendo 327 artigos, sendo estes ainda não utilizáveis pelo classificador, estando sujeitos a passar por processamento de texto.

Para uma maior precisão na etapa da classificação do *corpus*, é introduzido uma palavra-chave a mais na lista, o campo *index*. Este campo possibilitará o manuseio dos dados pelo algoritmo do classificador a ter melhor acesso aos rótulos de classificação, isso ajudará a encontrar o melhor hiperplano com a técnica *grid search* para o classificador, como será demonstrado mais à frente.

Mas primeiramente precisa-se converter a lista com os quatro campos em um *dataframe* Pandas. Esta é uma representação em tabela de dados retangular que contém uma coleção ordenada de colunas, em cada uma pode ter um tipo de valor diferente. O diferencial que o *dataframe* Pandas tem em relação a uma simples lista Python é que, este tem índice tanto para linhas quanto para colunas, facilitando assim tanto a visualização do conteúdo quanto a manipulação dos dados contidos, ajudando na classificação utilizada pelos algoritmos. Este processo pode ser visualizado na Fig. 19 [106, 107].

Corpus (DataFrame)

	index	indice	classificacao	titulo	abstracti
0	0	138	1	Studies in the modified Scoliosis Research Soc...	STUDY DESIGN: Observational study of patients ...
1	1	192	0	Health related quality of life and patient rep...	OBJECTIVE: To evaluate health-related quality ...
2	2	197	0	Effectiveness and tolerability of the buprenor...	BACKGROUND: A new transdermal delivery system ...
3	3	198	1	Outcome of adenotonsillectomy for severe obstr...	OBJECTIVE: To study changes in sleep behavior ...
4	4	229	0	Gastric adenocarcinoma screening and preventio...	OBJECTIVE: To estimate the cost-effectiveness ...

Figura 19 - Corpus em formato dataframe pandas com a coluna index adicionada.

Depois de ter o *corpus* ajustado, é utilizado a técnica de *oversampling*, para balancear os dados. Esta técnica é a mais adequada para este tipo de situação, fazendo com que a amostragem minoritária seja balanceada estatisticamente, sem muitas perdas de informações.

Classificação 0: 265
Classificação 1: 62
Proporção: 4.27 : 1




Figura 20 - Contagens das classificações antes do balanceamento.

No gráfico da Fig. 20, pode-se visualizar que a proporção de artigos classificados em relação ao volume do *corpus*, com um total de classificação relevantes (1) é baixa, favorecendo a classificação majoritária, não relevante (0).

Classificação 0: 265
Classificação 1: 265
Proporção: 1.0 : 1




Figura 21 - Contagens das classificações após do balanceamento.

Com a utilização da técnica de reamostragem; *oversampling*, o *corpus* se torna balanceado, fazendo a sintetização de 203 artigos a mais para classificação positiva, aumentando o percentual de acertos na classificação dos artigos com um número total de 530 artigos. Essa técnica de reamostragem foi escolhida pela natureza do *corpus* em que este trabalho se baseia, sendo um conjunto de dados de dimensionalidade baixa e com pouca classificação “relevante”. O método de *oversampling* foi o mais adequado para a reestruturação da classificação do *corpus*, deixando o *corpus* numa proporção de 50% para ambas as classes, como mostra a Fig. 21, ajudando na classificação supervisionada que será discutida mais adiante.

4.2. Aplicando o modelo probabilístico em conjunto com classificador supervisionado

A metodologia utilizada neste trabalho tem seu alicerce na classificação supervisionada, utilizando o classificador SVM. Para ter uma maior precisão deste classificador, é utilizado o modelo probabilístico LDA, o objetivo deste é mapear todos os tópicos que constituem os artigos contidos no *corpus*, de modo que as palavras em cada documento sejam capturadas principalmente por esses tópicos imaginários (latente, tópicos que passam despercebidos em uma leitura). Para que possa ser obtido este recurso, o LDA utiliza de representações baseadas em agrupamentos (*clusters*), que são induzidos em todo o conjunto de artigos, e a sua forma de tratamento dos artigos, difere do classificador SVM [20, 48].

Para realizar este procedimento do conteúdo no *corpus*, faz-se necessário um pré-processamento dos artigos, como:

- Remoção de pontuação e outros tipos de caracteres desnecessários com ajuda de tokenização e técnicas NLP baseadas em *regex*.
- Remoção de *stopwords*.
- Lematização: neste trabalho esta técnica foi utilizada pelos motivos de apresentar menos perdas nas sentenças ou no sentido das frases quando se faz junção de termos com técnica uni-gramas e bi-gramas.

Após este procedimento, o *corpus* concedido na triagem, está mais apto a passar pelo processo de classificação proposto para o auxílio a RS.

Estando o método probabilístico utilizado nesta dissertação empregado pela biblioteca *Gensim*, esta cria dois tipos de dados utilizados pelo modelo estatístico LDA, a saber: dicionário e o *corpus* que neste caso é representado como modelo BoW. O dicionário possui o registo de todas as palavras contidas no *corpus*, atribuindo um identificador ao termo, como pode ser observado na Fig. 22.

O BoW gerado pelo LDA, é um ajuste de todos os documentos, tendo em sua composição a representação matricial entre artigos e palavras. Estando as palavras representadas por identificadores numéricos e o número de frequência ocorrida no documento, sua utilização é para fins de busca de modelos na matriz de termo documento, isto pode ser observado na Fig. 23 [18, 64].

```
In [27]: 1 print(id2word.id2token)

{0: 'actrn', 1: 'adelaide', 2: 'adherence', 3: 'adjusted', 4: 'advancement', 5: 'ambulatory', 6: 'among', 7: 'anzctr', 8: 'apnea', 9: 'appropriate', 10: 'a', 12: 'baseline', 13: 'bound', 14: 'care', 15: 'center', 16: 'centers', 17: 'change', 18: 'cl', 19: 'clinical', 20: 'comparable', 21: 'compare', 22: 'co', 24: 'conservative', 25: 'continuous_positive_airway_pressure', 26: 'controlled', 27: 'costs', 28: 'daytime_sleepiness', 29: 'decreased', 30: 'dem', 32: 'diagnosis', 33: 'difference', 34: 'differences', 35: 'disease', 36: 'due', 37: 'efficacy', 38: 'epworth_sleepiness_scale', 39: 'ess', 40: 'general', 'group', 43: 'groups', 44: 'growing', 45: 'health', 46: 'high', 47: 'hospital', 48: 'ideally', 49: 'identifier', 50: 'importance', 51: 'improvements', 52: 'ncreasing', 54: 'interest', 55: 'interventions', 56: 'involving', 57: 'june', 58: 'level', 59: 'life', 60: 'lower', 61: 'main', 62: 'management', 63: 'man', 65: 'mean', 66: 'measures', 67: 'medicine', 68: 'metropolitan', 69: 'model', 70: 'models', 71: 'modes', 72: 'month', 73: 'months', 74: 'noninferior', 'y', 76: 'objective', 77: 'obstructive', 78: 'org', 79: 'outcome', 80: 'outcomes', 81: 'patient', 82: 'patients', 83: 'physicians', 84: 'plans', 85: 'point', 87: 'practices', 88: 'primary', 89: 'quality', 90: 'randomized', 91: 'ranges', 92: 'regions', 93: 'relative', 94: 'relevance', 95: 'result', 96: 'resu', 8: 'rural', 99: 'satisfaction', 100: 'score', 101: 'scores', 102: 'secondary', 103: 'september', 104: 'services', 105: 'setting', 106: 'seventeen', 107: 'ficant', 109: 'simplified', 110: 'sleep', 111: 'sleepiness', 112: 'south', 113: 'specialist', 114: 'specific', 115: 'splints', 116: 'study', 117: 'suggest', 119: 'tools', 120: 'training', 121: 'treated', 122: 'treatment', 123: 'trial', 124: 'trial_registration', 125: 'university', 126: 'using', 127: 'usual', 'withdrew', 130: 'within', 131: 'worse', 132: 'according', 133: 'age', 134: 'aged', 135: 'aim', 136: 'arthritis', 137: 'based', 138: 'better', 139: 'cance', 141: 'comparison', 142: 'completed', 143: 'conclusion', 144: 'conducted', 145: 'core', 146: 'data', 147: 'date', 148: 'declined', 149: 'depression', 150: 'diseases', 152: 'education', 153: 'eligible', 154: 'eortc', 155: 'eortc_q1q', 156: 'european_organization', 157: 'evaluating', 158: 'fatigue', 159: 'fema', 161: 'frequently', 162: 'function', 163: 'functioning', 164: 'generally', 165: 'generate', 166: 'german', 167: 'germany', 168: 'higher', 169: 'hyperlipide', 'nsion', 171: 'increased', 172: 'insomnia', 173: 'items', 174: 'latter', 175: 'lifetime', 176: 'maximum', 177: 'measured', 178: 'men', 179: 'methods', 180: 'irrored', 182: 'missing', 183: 'normative', 184: 'northern', 185: 'older', 186: 'pain', 187: 'participants', 188: 'persons', 189: 'population', 190: 'post', 't', 192: 'prevalence', 193: 'procedures', 194: 'prooortion', 195: 'provided', 196: 'published', 197: 'q1q', 198: 'qol', 199: 'questionnaire', 200: 'questi', }
```

Figura 22 - Pequeno exemplo do dicionário utilizado pelo modelo LDA.

```

Doc1: 1
[(0, 1), (1, 1), (2, 1), (3, 1), (4, 1), (5, 1), (6, 1), (7, 1), (8, 1), (9, 2), (10, 1), (11, 1), (12, 2), (13, 2), (14,
1), (15, 1), (16, 1), (17, 1), (18, 1), (19, 1), (20, 2), (21, 1), (22, 1), (23, 2), (24, 2), (25, 1), (26, 2), (27, 1), (28,
1), (29, 1), (30, 1), (31, 3), (32, 1), (33, 3), (34, 1), (35, 3), (36, 9), (37, 1), (38, 1), (39, 6), (40, 1), (41, 1), (42,
1), (43, 1), (44, 2), (45, 1), (46, 1), (47, 1), (48, 1), (49, 1), (50, 1), (51, 1), (52, 2), (53, 1), (54, 1), (55, 1), (56,
1), (57, 1), (58, 1), (59, 1), (60, 1), (61, 1), (62, 1), (63, 1), (64, 1), (65, 1), (66, 1), (67, 1), (68, 1), (69, 1), (70,
1), (71, 2), (72, 1), (73, 1), (74, 1), (75, 1), (76, 1), (77, 1), (78, 3), (79, 1), (80, 1), (81, 1), (82, 2), (83, 2), (84,
1), (85, 1), (86, 1), (87, 1), (88, 1), (89, 2), (90, 1), (91, 1), (92, 1), (93, 8), (94, 1), (95, 1), (96, 4), (97, 2), (98,
1), (99, 1), (100, 1), (101, 1), (102, 1), (103, 1), (104, 1), (105, 1), (106, 1), (107, 1), (108, 1), (109, 1), (110, 1), (1
11, 1), (112, 1), (113, 1), (114, 1), (115, 1), (116, 1), (117, 1), (118, 1), (119, 1), (120, 1), (121, 1), (122, 2), (123,
1), (124, 1)]

Doc1: 2
[(16, 1), (30, 1), (48, 1), (61, 4), (93, 4), (100, 1), (103, 1), (105, 1), (111, 1), (113, 1), (114, 2), (125, 1), (126,
1), (127, 1), (128, 1), (129, 1), (130, 1), (131, 2), (132, 1), (133, 5), (134, 1), (135, 1), (136, 1), (137, 1), (138, 1),
(139, 5), (140, 1), (141, 2), (142, 3), (143, 1), (144, 1), (145, 1), (146, 1), (147, 1), (148, 1), (149, 1), (150, 2), (151,
1), (152, 2), (153, 1), (154, 1), (155, 2), (156, 1), (157, 1), (158, 1), (159, 1), (160, 2), (161, 1), (162, 1), (163, 1),
(164, 1), (165, 1), (166, 1), (167, 2), (168, 1), (169, 4), (170, 1), (171, 1), (172, 1), (173, 2), (174, 1), (175, 1), (176,
1), (177, 1), (178, 1), (179, 1), (180, 1), (181, 1), (182, 1), (183, 1), (184, 3), (185, 1), (186, 1), (187, 1), (188, 1),
(189, 1), (190, 1), (191, 1), (192, 1), (193, 1), (194, 1), (195, 2), (196, 1), (197, 1), (198, 1), (199, 1), (200, 1), (20

```

Figura 23 - Pequeno exemplo do BoW utilizado pelo modelo LDA contendo somente as referências como id das palavras e seu número de vezes que aparecem no artigo.

Na etapa da preparação do dicionário e BoW, o LDA aplica um filtro para gerenciar o número de termos que esteja entre um limite, não podendo estar muito ou pouco presente nos artigos, pois eles podem distorcer os resultados, definindo assim o limite entre 0.2% a 80%. Deste modo, os tópicos serão formados somente por palavras com ocorrências neste intervalo [39, 108].

Com o *corpus* e o dicionário processado pelo LDA, pode-se definir o número de tópicos, onde k é a representação deste número denotado entre os valores de $k = 10, 20, 50, 100, 150$ e 200. Mas na realidade não existe um valor de k que atenda todos os eventos baseados em tópicos. Geralmente este número é baseado em conhecimentos prévios da base de informação que se tem. No caso em que há uma coleção de textos pequeno, obviamente este número de tópicos não será muito grande.

O valor de k ajuda a melhorar a representação dos termos em tópicos, sendo seu acesso na base de artigos presente no *corpus*. Para isso, este valor utiliza de dois hiper-parâmetros: o α e β , onde ajuda a definir se os tópicos serão mais gerais ou detalhados [39].

$$\alpha = \frac{1}{numero_{topicos}} \quad (26)$$

Para obter essas informações do modelo de tópicos, é necessário passar como parâmetro o *corpus*, o dicionário e o número de tópicos desejado para a função que representa o LDA. Estes são processados com a iteração de cada valor de k , sendo guardado os resultados numa variável criada pelo modelo, tendo seu nome por padrão, *model*, ou modelo LDA, contendo o seu modelo para aquele *corpus* analisado. Esta classe é acessada através da biblioteca *Gensim*, para posteriores avaliações dos tópicos extraídos. Na Fig. 24 mostra um pequeno trecho do algoritmo da representação do modelo LDA.

```

1 //Execução do LDA baseado na biblioteca Gensim
2
3
4 dictionary = gensim.corpora.Dictionary.load ('dictionary.dict')
5 corpus = gensim.corpora.MmCorpus ('corpus.mm')
6 Lda = gensim.models.ldamodel.LdaModel
7 ldamodel = Lda (corpus, num_topics=50, id2word = dictionary)
8
9 print (ldamodel.print_topics (num_topics=50, num_words=10))
10
11 ldamodel.save ('lda/lda50.model')
12

```

Figura 24 - Pseudocódigo do modelo LDA. Observação; o parâmetro num_topics é o mesmo termo k.

Um facto interessante a se constatar na função do modelo LDA em Python, é o parâmetro *passes* (Fig. 25). Este controla as frequências ou os ciclos com que é agrupado os tópicos do modelo em todo o *corpus* fazendo uma revisão de cada etapa do ciclo que a classe LDA faz. Esta questão pode ser um tanto técnica, mas é essencial para o controle da qualidade do modelo que será entregue. É importante definir o número de *passes* para que as iterações de tópicos sejam suficientes, quanto maior for o número de *passes* mais demorado será a execução da classe LDA por motivos de revisão.

Segundo [108, 109], para escolher o número de interações de *passes* mais exato, é aconselhável ativar o parâmetro que controla a perplexidade de log (equação 17), configurando o com valor igual a 1. Processando o modelo com esse parâmetro igual a 1, aparecerá linhas de registos (*logs*) semelhante a seguinte:

```

2019-11-30 02:55:08,650 - gensim.models.MODELO_LDA - DEBUG - 50/530 documents
converged within 100 iterations

```

Se é definido *passes* = 25, observará esta linha acima 25 vezes para um número exato. Se a quantidade de vezes da linha a cima não for igual a 25, então conclui-se que o número na variável *passes* está fora do ideal, podendo ser para mais do que 25 vezes ou para menos [109]. É preciso certificar-se de que pelos ciclos finais, a maioria dos documentos tenham convergido. Se tudo acontecer como o explicado, o número devolvido pela perplexidade de log será o ideal para poder fazer parte das interações do modelo LDA. Outro fator importante a desenvolver

para um bom modelo de tópicos, é a questão do paralelismo, este trabalho foi desenvolvido com processos desta tecnologia.

A biblioteca *Gensim*, disponibiliza uma técnica em que o utilizador, pode fazer uso dos núcleos do processador do computador, dando assim uma maior agilidade no processo de montar o modelo LDA. Esta etapa é marcada pelo parâmetro *workers = cpu_count - 1*, onde *cpu_count* é uma variável que conterá o número de CPU, O número -1, é uma forma de evitar que o utilizador da biblioteca não caia na tentação de usar todos os núcleos do processador [109]. Abaixo na Fig. 25 é demonstra a configuração do modelo LDA utilizado pelo algoritmo de classificação.

```
#modelos de LDA, Mallet, Coerência e Perplexidade
#criando modelo LDA (obs: o método LdaMultiCore é utilizado espeicilmente para fins de processadores multicore)

cpu_count = 8

%%time
MODELO_LDA = LdaMulticore(corpus          = corpus,      # corpus
                          id2word         = id2word,      # dicionário
                          random_state    = 10,          # Faz o embaralhamento aleatório do corpus, quanto maior o numero de
                          num_topics      = 10,          # O número de tópicos latentes solicitados a serem extraídos do corpus
                          passes          = 25,          # Número de passes pelo corpus durante o treinamento, faz uma revisão
                          chunksize       = 100,          # Número de documentos a serem usados em cada bloco de treinamento.
                          batch           = False,
                          alpha           = 'asymmetric', # multicore
                          decay           = 0.5,
                          offset          = 64,          # Hiper-parâmetro que controla quanto desaceleraremos os primeiros
                          eta             = None,
                          eval_every      = 1,          # A perplexidade do log é estimada a cada atualização. Definir isso
                          iterations     = 100,          # Número máximo de iterações através do corpus ao inferir a distrib
                          gamma_threshold = 0.002,       # Alteração mínima no valor dos parâmetros gama para continuar iter
                          per_word_topics = True,
                          workers        = cpu_count - 1 )
```

Figura 25 - LDA em Python, parâmetros que compõem a função LDA.

Neste trabalho foi proposto um modelo LDA com o valor de $k = 100$, com número de *passes = 25*. Posteriormente será utilizado a mesma configuração para a biblioteca Mallet. Segundo os autores de [110, 111], Mallet é um pacote baseado na linguagem Java para processamento estatístico de linguagem natural, classificação de documentos, agrupamento, modelagem de tópicos, extração de informações e outros aplicativos de aprendizado de máquina em texto.

Mallet utiliza da Alocação de Dirichlet Latente (LDA), Alocação de Pachinko (PAM) um modelo que captura correlações arbitrárias, aninhadas e possivelmente esparsas entre tópicos usando um gráfico acíclico direcionado, fornecendo uma alternativa flexível ao trabalho recente de Blei e Lafferty (2006), que captura correlações apenas entre pares de tópicos [112],

e a Alocação Dirichlet Latente Hierárquica (hLDA) para modelagem de tópicos onde são reunidos em uma hierarquia usando os processos, cuja estrutura é aprendida com os dados[113].

Esta biblioteca oferece uma melhor qualidade de tópicos em relação à técnica pura de LDA. O *Gensim* disponibiliza um invólucro para implementar o LDA junto ao Mallet. O modelo LDA utilizado em conjunto com o pacote Mallet é construído com 100 tópicos diferentes, onde cada tópico é uma combinação de termos-chave e cada termos-chave contribui com uma certa ponderação para o tópico conforme visto na seção 3.5.2.

Uso do Mallet Modelo de Tópicos <pre>[55, '0.233*qol' + 0.080*life' + 0.062*quality' + 0.038*study' + ' '0.025*significant' + 0.025*hr' + 0.021*social' + 0.019*version' + ' '0.017*whoqol' + 0.016*characteristics'), 50, '0.083*osa' + 0.062*apnea' + 0.062*obstructive' + 0.056*sleep' + ' '0.042*quality' + 0.039*score' + 0.031*children' + 0.027*life' + ' '0.027*symptom' + 0.025*fatigue'), 32, '0.061*questionnaire' + 0.052*age' + 0.036*high' + 0.034*score' + ' '0.030*psychological_distress' + 0.028*relationship' + 0.026*median' + ' '0.023*assessment' + 0.021*multiple_tender_points' + 0.019*subjects'), 73, '0.056*analysis' + 0.049*data' + 0.035*costs' + 0.028*cattle' + ' '0.028*cost' + 0.023*estimated' + 0.023*traditional' + 0.023*receiving' + ' '0.021*forms' + 0.021*metoclopramide'), 41, '0.061*pain' + 0.044*months' + 0.037*chronic' + 0.033*methods' + ' '0.031*life' + 0.031*active' + 0.030*hospital' + 0.028*stage' + ' '0.022*groups' + 0.022*mesh'), 28, '0.070*insomnia' + 0.041*sleep' + 0.041*treatment' + 0.026*cbt' + ' '0.022*group' + 0.019*hypnotic_drug' + 0.018*treated' + 0.016*outcomes' + ' '0.016*months' + 0.015*month'), 14, '0.077*screening' + 0.043*cost_effectiveness' + 0.040*cost' + ' '0.027*based' + 0.024*risk' + 0.022*costs' + 0.022*treatment' + ' '0.020*analysis' + 0.017*adjusted' + 0.017*strategy'), 85, '0.073*patients' + 0.063*life' + 0.055*quality' + 0.044*group' + ' '0.038*significant' + 0.033*functional' + 0.029*groups' + ' '0.026*cordectomy' + 0.024*statistically' + 0.022*study'), 72, '0.069*cancer' + 0.061*treatment' + 0.050*qol' + 0.032*ortic_qlq' + ' '0.028*life' + 0.027*fatigue' + 0.024*scales' + 0.021*questionnaire' + ' '0.019*nausea_vomiting' + 0.018*survival'),</pre>	Uso do LDA Modelo de Tópicos <pre>[58, '0.000*patients' + 0.000*degrees' + 0.000*implant_removal' + ' '0.000*significantly' + 0.000*time' + 0.000*assays' + 0.000*years' + ' '0.000*percent_predicted' + 0.000*instrumentation_none' + ' '0.000*similar_operation'), 99, '0.000*kccq' + 0.000*patients' + 0.000*heart_failure' + 0.000*measures' + ' '0.000*bnrp' + 0.000*osa' + 0.000*changes' + 0.000*baseline' + ' '0.000*quality' + 0.000*status'), 96, '0.018*sleep' + 0.016*symptoms' + 0.016*one' + 0.016*gerd' + ' '0.015*vonoprazan' + 0.015*patients' + 0.014*associated' + ' '0.013*questionnaire' + 0.013*psychological_distress' + 0.012*year'), 97, '0.000*multinorbidity' + 0.000*among' + 0.000*positive' + 0.000*hiw' + ' '0.000*art' + 0.000*epilepsy' + 0.000*camps' + 0.000*appropriate' + ' '0.000*searched' + 0.000*membership'), 93, '0.046*kccq' + 0.018*correlation' + 0.018*perceived' + 0.016*score' + ' '0.016*functional' + 0.014*status' + 0.012*physician' + 0.011*hcm' + ' '0.011*ryha_class' + 0.010*correlations'), 94, '0.000*patients' + 0.000*depression' + 0.000*anxiety' + 0.000*life' + ' '0.000*effect' + 0.000*quality' + 0.000*study' + 0.000*significantly' + ' '0.000*epilepsy' + 0.000*improvements'), 95, '0.024*patients' + 0.016*epilepsy' + 0.014*scale' + ' '0.013*turkish_version' + 0.013*scores' + 0.012*life' + 0.012*quality' + ' '0.011*mini_oqlq' + 0.011*study' + 0.011*compared'), 92, '0.000*genital' + 0.000*skills' + 0.000*coping' + 0.000*screening' + ' '0.000*stress' + 0.000*hsv' + 0.000*treatment' + 0.000*quality' + ' '0.000*management' + 0.000*episodes'), 91, '0.000*patients' + 0.000*hen' + 0.000*quality' + 0.000*one' + ' '0.000*study' + 0.000*zygomatic_implants' + 0.000*procedure' + ' '0.000*suffer' + 0.000*inflamed' + 0.000*four'),</pre>
--	---

Figura 26 - Tópicos no modelo LDA e o modelo sendo utilizado junto a biblioteca Mallet.

A Fig. 26, pode ser interpretada da seguinte forma; será analisado o tópico 72 da classificação feita com a biblioteca Mallet. Este pode ser descrito como as 10 principais palavras-chave que contribuem para este tópico, que são: 'cancer', 'treatment', e assim por diante, e o peso de 'cancer' no tópico 72 é 0.069. Os pesos refletem a importância de uma palavra-chave para este tópico escolhido, oferecendo uma maneira simples de examinar o tema que aquele tópico está a tratar, neste caso do tópico 72, pode-se observar que se trata do tema: tratamento contra o câncer e suas consequências.




Figura 27 - Outra maneira de visualizar os principais tópicos com uso do pacote Python, pyLDAvis.

Para ter uma visualização melhor do que na Fig. 28, é utilizado o pacote pyLDAvis, encontrada na biblioteca *Gensim*. Este oferece uma forma dinâmica de fazer uma análise entre os termos que podem estar sendo compartilhados por diferentes tópicos.

Na Fig.27, mostra que as bolhas no gráfico do lado esquerdo representam os tópicos, onde tem sua importância, sendo medido pelo seu tamanho. Quando no modelo de tópico há bolhas grandes que não sobreponham uma a outra e espalhadas pelo gráfico, pode ser considerado um bom modelo. Quando há um k muito grande, haverá sobreposição de tópicos em pequenas bolhas em determinada posição do gráfico, causando granularidade nos subtópicos que compõem os tópicos [114].

Para que não haja perda de tempo na procura manual de um número de tópicos adequado, muitas vezes se faz necessário o uso de cálculos através da coerência. Esta medida é tomada através do número ideal de k tópicos, sendo analisado para esta questão de $n = 1, 2, 3, \dots, k$, e escolhendo o que oferece o maior valor de coerência (veja seção 3.5.2).




Figura 28 - Pontos de Coerência e Valor da coerência.

A ideia do gráfico da Fig. 28 é trazer para o investigador o número mais próximo do ideal de tópicos, construindo muitos modelos de LDA com diferentes valores de k e escolher o que fornece o maior valor de coerência. Escolhendo um valor de k marcando o fim do crescimento rápido da coerência de tópicos, geralmente oferece tópicos mais significativos e interpretáveis. Escolher um valor ainda mais alto às vezes pode fornecer subtópicos mais granulares [108, 109].

Se o tópico contiver as mesmas palavras-chave repetidas em vários tópicos vizinhos, provavelmente é um sinal de que o ' k ' é muito grande.

Nº Tópicos = 2	tem um valor de coerência de	27.0 %
Nº Tópicos = 8	tem um valor de coerência de	33.0 %
Nº Tópicos = 14	tem um valor de coerência de	33.0 %
Nº Tópicos = 20	tem um valor de coerência de	36.0 %
Nº Tópicos = 26	tem um valor de coerência de	35.0 %
Nº Tópicos = 32	tem um valor de coerência de	36.0 %
Nº Tópicos = 38	tem um valor de coerência de	37.0 %
Nº Tópicos = 44	tem um valor de coerência de	40.0 %

Maior Coerencia...: 40.0 %

Figura 29 - Pontuações de coerência.

O valor de k escolhido neste contexto, foi $k = 20$, onde pode-se observar que na posição 20, o gráfico começa a se achatar (Fig. 28) e logo depois, cresce exponencialmente. Com valor de k muito grande, como mencionado antes, pode causar palavras-chave repetidas em vários tópicos. Este processo de escolha de melhor número de tópico, leva um certo tempo a ser considerado, pelo motivo que a função desenvolvida para este serviço, faz o cálculo de coerência por cada artigo a ser averiguado pelo modelo LDA. Na Fig. 29 é apresentado a coerência para cada tópico e mostrado a maior coerência destes.

Comparações com os valores de Coerências

```

Perplexidade do modelo.: -14.74
*****

Pontos de Coerência(Mallet).: 0.46
Pontos da Coerência(LDA).: 0.53

```

Figura 30 - Métricas utilizadas de Perplexidade e Coerência do modelo LDA e Mallet.

Como mencionado antes no subcapítulo 3.5.3, quanto menor a perplexidade de log menor a taxa de erro, já os pontos de coerência quanto maior melhor, podendo ser comprovado na Fig. 30 com a comparação entre o modelo LDA e o LDA sendo utilizando junto com o Mallet.

Documento mais representativo para cada tópico

Nº_Topic	Topic_Perc_Contrib	Palavra_Chave	Abstract (Doc)
0	0.0	0.76 groups, degrees, study, questionnaire, analysi...	[214, 11268, 1, Discriminative validity of the...
1	1.0	0.83 treatment, sleep, quality, insomnia, patients,...	[35, 1482, 1, Psychological treatment for inso...
2	2.0	0.76 patients, group, life, disease, scores, compar...	[13, 623, 1, Epilepsy in patients with primary...
3	3.0	0.60 screening, results, data, included, based, adj...	[204, 10880, 0, Cost-effectiveness of differen...
4	4.0	0.81 study, sf, adults, health, specific, srs, asse...	[0, 138, 1, Studies in the modified Scoliosis ...
5	5.0	0.78 patients, follow, years, clinical, year, repor...	[178, 9493, 1, Clinical and radiographic resul...
6	6.0	0.54 sleep, quality, study, reported, symptoms, obs...	[304, 15893, 1, Assessment of the psychologica...
7	7.0	0.65 epilepsy, qol, seizure, variables, related, li...	[44, 1983, 1, Comorbidity of body dysmorphic d...
8	8.0	0.66 treatment, hiv, mg, months, study, improved, p...	[173, 9245, 1, Clinical outcomes using ClearPo...
9	9.0	0.46 qol, reported, symptoms, cancer, study, popula...	[279, 14718, 0, Italian National Survey of Dig...
10	10.0	0.62 patients, quality, life, surgery, complication...	[86, 3865, 1, Complications after surgery for ...
11	11.0	0.70 children, health, life, quality, study, relate...	[134, 6874, 1, Trajectories of health-related ...
12	12.0	0.76 score, kccq, status, health, patients, functio...	[171, 9190, 1, Correlations between physician-...
13	13.0	0.53 care, patients, patient, outcomes, disease, ma...	[307, 15957, 0, Practices of traditional beef ...
14	14.0	0.63 health, women, men, life, quality, related, sy...	[72, 3292, 1, Onabotulinum toxin A Injections ...
15	15.0	0.67 patients, hrqol, life, quality, questionnaire,...	[206, 10969, 1, Development of a Persian Versi...
16	16.0	0.68 patients, depression, pain, anxiety, symptoms,...	[161, 8473, 1, Prevalence of neuropathic pain ...
17	17.0	0.62 physical, function, weeks, quality, emotional,...	[303, 15812, 1, Health-related Quality of Life...
18	18.0	0.70 patients, therapy, intervention, years, group,...	[99, 4623, 1, Effect of Trimetazidine Dihydroc...
19	19.0	0.64 age, questionnaire, score, relationship, life,...	[150, 7723, 1, The relationship between psycho...

Figura 31 - Documento mais representativo para cada tópico.

Na Fig. 31 mostra-se a percentagem de contribuição dos tópicos (palavras-chave) em cada documento analisado. Com os resultados do modelo probabilístico concluídos, é obtido um novo *corpus*, onde consta novos parâmetros. Este *corpus* montado pelo LDA é utilizado

pelo classificador supervisionado SVM, que tem em sua estrutura de classificação o objetivo de fazer análise de polaridade em “relevante” ou “não relevante” para o caso desta dissertação.

É iniciado o processo de extração de recursos mais conhecido como extração de características, através do treinamento do classificador, nessa dissertação é utilizado a medida estatística *TF-IDF* em conjunto com o classificador SVM. Para se ter um maior desempenho da técnica SVM, foi proposto encontrar o melhor hiper-parâmetro deste classificador, fazendo ajustes para o aprimoramento do desempenho e de sua taxa de aprendizagem.

Geralmente o SVM pode oferecer muitos hiper-parâmetros, e encontrar o modelo certo para a classificação pode tornar o serviço muito árduo, mas para essa tarefa foi utilizado a técnica chamada *grid search*, um buscador de melhor solução de hiper-parâmetros que avaliará todas as combinações passadas através de um dicionário e utilizará cálculos de validação cruzada para chegar a esse resultado[38, 115].

Na Fig. 32 pode-se observar como é a estrutura interna do *grid search* com seus ciclos de processamento.




Figura 32 - Ilustração do Ciclo de um Grid-Search na busca de Parâmetros Ótimos [115].

Para essa tarefa fez-se necessário dividir o *corpus* em uma proporção de 70% dos artigos para treino, e 30% para testes, utilizando o modelo de função *SVC()* (*support vector classification*), da biblioteca *scikit-learn*. Esta função é utilizada em sua forma padrão porque o conjunto de dados utilizados nesta dissertação é relativamente pequeno, neste caso não será necessário utilizar classes mais específicas como a *LinearSVC()*, também pertencente a

biblioteca *scikit-learn* que apresenta um desempenho maior com grandes conjuntos de dados[38, 117]. Sem passar por nem um ajuste de busca do melhor hiper-parâmetros, pode-se constatar que o classificador tem uma proporção favorável a classe “não relevante”.

	precision	recall	f1-score	support
0	0.51	0.77	0.61	56
1	0.41	0.18	0.25	50
accuracy			0.49	106
macro avg	0.46	0.47	0.43	106
weighted avg	0.46	0.49	0.44	106

Figura 33 - Classes sem nem um tipo de ajuste do hiper-parâmetros.

Como pode-se observar na Fig. 33, as classes classificadas pelo SVC, sem nem um tipo de hiper-parâmetro ajustado, mostra em sua forma que o *corpus* por mais que esteja balanceado pelo processo de *oversampling*, ainda tem suas diferenças quanto ao grau de polarização.

Na Fig. 34, ao utilizar o método do *grid search*, o hiper-parâmetro foi ajustado para uma melhor precisão na classificação “relevante”, 1 em 100%. Observando que estes resultados se baseiam no estado do *corpus* balanceado com processamento do método estatístico LDA.

	precision	recall	f1-score	support
0	0.95	1.00	0.97	56
1	1.00	0.94	0.97	50
accuracy			0.97	106
macro avg	0.97	0.97	0.97	106
weighted avg	0.97	0.97	0.97	106

Figura 34 -Classes com ajuste do hiper parâmetros.

Melhor ajuste de hiper-parâmetros encontrados com a utilização do método *grid search*:

```
Melhor parâmetro após o ajuste...: {'C': 1, 'gamma': 1, 'kernel': 'linear'}
Melhor Modelo para o SVM...:
SVC(C=1, gamma=1, kernel='linear')
```

Figura 35 - Hiper-parâmetros ajustado e com kernel linear.

Onde os parâmetros mostrados na Fig. 35 podem ser entendidos como:

C: Regularização do hiper-parâmetro sendo com valor igual a 1

Gamma: Ajustando para hiperplanos lineares, valor 1, igual a linear

Kernel: hiperplano linear, separando os “relevante” dos “não relevante”

Após a conclusão do processo do *grid search*, o melhor ajuste de hiper-parâmetro, é considerado $C = 1$ com *kernel: linear*, oferecendo uma melhora na classificação supervisionada como será demonstrado logo depois dos resultados com o ajuste.

4.3. Extração de características com base na técnica k-fold

Para a avaliação do modelo de classificador utilizado, é empregado a técnica de validação cruzada, que faz a análise a partir de um conjunto de dados, buscando estimar a precisão do classificador. Esta técnica tende a acrescentar dados na parte em que vai ser destinado a treinar o classificador. Para o desenvolvimento da validação cruzada nesta dissertação, é empregado a técnica *k-fold* com a biblioteca *scikit-learn*.

A técnica *k-folds* tem em sua base, o conceito de divisão do conjunto de informações em subconjuntos menores, mutuamente exclusivos para poder ser utilizados na estimação dos parâmetros do modelo de classificação (dados de treinamento), deixando o restante dos dados dos subconjuntos (dados para validação ou teste) a cargo na validação do modelo [38, 115].

A divisão da técnica de validação cruzada é regida na seguinte condição: o *corpus* a ser analisado neste exemplo é utilizado na notação d para demonstrar o *corpus* como um documento único, este é dividido em K partes, $(d_1, d_2, d_3, \dots, d_K)$. Esta escolha é adotada pelo desenvolvedor do classificador, mas segundo o autor de [38], o padrão é dividir em 10 partes, de tamanhos parecidos m_k , em que $\sum_{k=1}^K m_k = n$, K sendo o número de interações de cada amostra de validação, será dada por d_k , com $k = 1, 2, 3, 4, \dots, K$.

Após esta amostra de treino do preditor, é analisado o conjunto das outras partes de $K - 1$, permanecendo da seguinte forma $d_{(-k)} = \{d_1, d_2, d_k - 1, d_k + 1, \dots, d_K\}$. Ao final do processo da validação cruzada com os K ciclos, os dados são utilizados tanto na parte de treino, quanto na parte de validação, esse tipo de validação cruzada utilizada nesta dissertação é chamado de *K - folds*, e é exemplificada pela seguinte fórmula matemática:

$$kfK = \frac{1}{K} \sum_{k=1}^K \frac{1}{m_k} \sum_{i=1}^{m_k} L(y_{ik}, \hat{f}_{(-k)}(x_{ik})) \quad (27)$$

Onde o preditor $\hat{f}_{(-k)}(x)$ é elaborado para as amostras de treino $d_{(-k)}$, sendo avaliado nas observações da amostra de teste d_k para todo $k = 1, 2, 3, 4, \dots, K$ [115].

A validação cruzada com o método $k - folds$, executa uma divisão dos dados através do valor K (número de partes) entre amostra de treino e de teste. Para fazer este serviço de divisão dos documentos nesta técnica de validação há uma tendência a diminuir o tamanho das amostras m_k quando o valor de K é aumentado, com este valor muito elevado faz com que tenha um custo computacional alto o que implica em amostras de testes pequenas, o que aumenta a variância. Segundo estudiosos do assunto, o valor ideal de K , estaria entre 2 e 10 [38, 15, 118].

Nesta dissertação será utilizado o valor de $K = 4$ com a opção de geração de números aleatórios com 2 tentativas. Essa aleatoriedade é a opção de embaralhar o conteúdo do *corpus* para poder ser dividido pela técnica $k-folds$, tendo neste valor um melhor desempenho para este tipo de *corpus* oferecido para este trabalho. O motivo é que esses dados não são muito volumosos, então não há necessidade de fatiar o *corpus* em unidades pequenas, mas em outra ocasião a necessidade de implementar a técnica de validação cruzada $k-folds$ com valor de $K = 10$, não seria uma má ideia.

Na Fig. 36 é exemplificado o modelo $k-folds$ com um conjunto de dados sendo dividido em K parte de tamanho m_k e com conjunto de treinamento de $K - 1$ ou seja $d_{(-k)} = \{d_1, d_2, d_k - 1, d_k + 1, \dots, d_k\}$.




Figura 36 - Exemplo de implementação da técnica de validação cruzada k-folds.

Com o valor $K = 4$, o corpus ficou dividido em 354 artigos para treinos e 176 artigos para testes, sendo estes em fase de processamento para a extração de características com a medida estatística *TF-IDF*. Abaixo na Fig. 37 apresenta-se um pedaço do código da parte da extração dos recursos dos arquivos de texto:

```
vectorizer = TfidfVectorizer(min_df=5,
                             max_df = 0.8,
                             sublinear_tf=True,
                             use_idf=True,
                             norm='l2',
                             encoding='latin-1',
                             ngram_range=(1, 2),
                             stop_words='english')

train_corpus_tf_idf = vectorizer.fit_transform(X_train)
test_corpus_tf_idf = vectorizer.transform(X_test)
```

Figura 37 - Demonstração da extração de recurso dos artigos com a medida estatista *TF-IDF*.

Este recurso cria a matriz *TF-IDF* que calcula os valores de contagem de palavras, cria um modelo baseado nas medidas *TF-IDF* e ajuda a converter dados de texto em formato numérico, onde o valor vetorial que ele gera são o produto desses dois termos. *TfidfVectorizer* fornece um vetor com nome *vectorizer*, para poder ser o modelo do recurso, é chamado à função *fit_transform*, um transformador para ajustar as instâncias dos dados, esta função é chamada

pelo vetor *vectorizer*, que conta com parâmetro de conjunto e de artigos para o treinamento e testes já divididos pelo método *k-folds*, sendo estas listas iteráveis de cadeias em que cada cadeia representa os conteúdos dos documentos contidos no *corpus*, tendo o conteúdo destas cadeias um número de documentos para cada lista. Abaixo é demonstrado um pequeno trecho do algoritmo que forma o classificador na Fig. 38 [38, 119, 76].

```
train_corpus_tf_idf = vectorizer.fit_transform(X_train)
test_corpus_tf_idf = vectorizer.transform(X_test)
```

Figura 38 - A função é chamada pelo vetor *vectorizer* que é o modelo advindo da função *TfidfVectorizer*, esta função leva como parâmetro, *X_train* e *X_test*.

Os resultados gerados por esta função *fit_transform*, são matrizes esparsas contendo a cadeia de números de cada documento da lista iterável, sendo a contagem de palavras ponderadas pela medida estatística *TF-IDF* e os pesos das palavras por documentos de comprimento fixo, para cada documento no conjunto de treinamento e teste, podendo ser também chamado de matriz termo documento [76].

Após o processamento dos textos contidos no *corpus* para o formato numérico, pode ser feito o treinamento do classificador SVM, com o seu hiper-parâmetro já ajustado pela técnica do *grid search*. Este classificador utiliza de dois parâmetros da matriz termo documento, sendo estes como treino e teste com os rótulos de classificação de polaridade, oriundos do *corpus*. O conteúdo destes rótulos, como mencionado, faz parte da classificação manual que foi feito pelos revisores humanos, que vincula cada artigo separado para treinos e para testes. Na Fig. 39 é mostrado como os rótulos são utilizados em forma de vetores.

```
y_train, y_test = rotulos[train_index], rotulos[test_index]
```

Figura 39 - Extração dos rótulos de polaridade da classificação.

O treinamento do classificador SVM é feito em conjunto com a técnica *k-fold*, não somente o classificador como as ponderações *TF-IDF*, isto pode ser explicado pelo facto de que o método de validação cruzada teve que ser implementado em um laço, onde a cada iteração da validação, é processado tanto a parte do *TF-IDF* como a parte do SVM.

Em cada iteração, o laço que compõe a validação cruzada, cria clones do classificador, treina esses clones na parte de treinamento e faz previsões na parte de testes, contando o número

de previsões corretas e entregando a proporção destas através da matriz de confusão, este tipo de desenvolvimento da validação cruzada é eficaz para ter maior controle dos dados a ser classificados[38]. Na Fig. 40 é exibido um trecho da implantação da técnica *k-folds* em português estruturado (Portugol).

```

para treino, teste ate k-folds(corpus, rotulos) faça
    Para cont ate treino faça
        x_traino <- corpus[cont]
    fim para

    Para cont ate teste faça
        x_teste <- corpus[cont]
    fim para

    y_traino <- rótulos[trano]
    y_teste <- rótulos[testes]

    vetorTFIDF <- TF-IDF()

    traino_corpus <- vetorTFIDF.tranformador(x_traino)
    teste_corpus <- vetorTFIDF.tranformador(x_teste)

    modeloClass <- classificadorSVC()

    modeloClass.tranformador(traino_corpus,y_traino)

    resultado <- modeloClass.predição(teste_corpus)
    Matriz_confusão_class <- Matriz_confusão_class + matrizConfusao(y_teste,resultado,rotulos[0,1])
fim Para

```

Figura 40 - Algoritmo da técnica *k-folds*, elaborado em algoritmo estruturado (Portugol). Demonstração das interações da validação cruzada com o classificador e o método TF-IDF.

A validação cruzada *k-folds* com $K = 4$ ou seja, com 4 partes, permitiu testar todos os arquivos do *corpus*, lembrando que, com o desequilíbrio deste conjunto de artigos, a classificação ficou praticamente polarizada em proporção de igualdade (Veja Fig. 21), levando a uma classificação mais justa ao obter as opiniões para a aprendizagem automática voltada a RS.

Para uma compreensão mais detalhada do algoritmo proposto para o auxílio a RS, na Fig. 41, é exibido com maior detalhe todo o desenvolvimento do algoritmo através da modelagem de fluxograma.




Figura 41 - Diagrama de Fluxograma representando cada etapa do algoritmo classificador.

4.4. Discussão dos resultados

Com um total de 530 artigos balanceados e polarizados como “relevante” e “não relevante”, é apresentado o número de artigos previstos corretamente, o número de artigos classificados incorretamente pelo classificador e junto pode-se fazer uma comparação do *corpus* balanceado e não balanceado com suas classificações.




Figura 42 - Matriz de confusão com o corpus balanceado e não balanceado e suas métricas.

Como comentado no subcapítulo 3.5.3, a matriz de confusão expõe muitas informações que precisam ser analisadas com maiores detalhes. Na Fig. 42 exibe que do lado esquerdo, há a matriz de confusão com *corpus* classificado e balanceado e do lado direito há a matriz de confusão com classificação do corpus não balanceado. Cada linha da matriz representa uma classe real, enquanto cada coluna representa uma classe prevista.

A primeira linha da matriz de confusão balanceada, considera os artigos “não relevante”: 216 deles foram corretamente classificados como “não relevante”, sendo chamado de verdadeiro negativo, TN. No segundo quadrante, sendo na mesma linha do primeiro quadrante, 49 artigos foram erroneamente classificados como “relevante”, sendo um falso positivo, FP. Na segunda linha, ou seja no terceiro quadrante, considerado os artigos “relevante”: estando 33 artigos classificados erroneamente como “não relevante”, chamado de falso negativo, FN, enquanto 232 artigos foram classificados como “relevante”, sendo chamado de verdadeiro positivo, TP.

Uma observação a ser notada para um classificador perfeito é: teria apenas verdadeiro positivos TP e verdadeiros negativos TN, fazendo com que a matriz de confusão tenha apenas valores diferentes de zero na sua diagonal principal (superior esquerda para inferior direita). Como pode ser observado, neste *corpus* utilizado com o ajuste do hiper-parâmetro e balanceado, obteve-se uma classificação quase que perfeita[38].

Como observado na matriz com *corpus* desequilibrado da Fig. 42, a proporção, 4.27 artigos “não relevante” para 1 artigo “relevante”, pode-se observar que a concentração de artigos como FN, falso negativo no *corpus* desequilibrado é muito grande, estando 94 artigos classificados erroneamente como “não relevante”.

Seguindo os mesmos passos do exemplo dos resultados para o *corpus* balanceado, é notável que o balanceamento das informações contidas no conjunto de dados é importante para obter respostas com maior precisão, ajudando tanto na classificação como também na organização das informações.

Pode-se deduzir que as informações quando tem uma classificação mais equilibrada, trás como resultado uma maior precisão e segurança na hora de utilizar o classificador em cima dos dados fornecidos, isto pode ser constatado na Tabela 4, fazendo uma comparação das métricas entre os dois tipos de *corpus*.

Abaixo na Tabela 4 e 5 é apresentado com uma melhor visualização, a comparação das métricas do classificador SVM com o conjunto de dados balanceado e não balanceado.




Tabela 4 - Comparação da classificação entre ambos os tipos de estado do corpus.




Tabela 5 - Comparação da classificação entre ambos os tipos de estado do corpus com suas porcentagens.

Como constatado, há uma grande diferença entre ambos os tipos dos resultados para os dois estados do *corpus*. Quanto mais equilibrado melhor será os resultados, e a quantidade de informações será levada em julgamento, obtendo-se uma melhor proporção dos resultados.

Para facilitar o trabalho dos revisores de não lerem todo o *abstract* que pode ser longo, é utilizado nesta parte da classificação dos artigos a sumarização de textos. Este auxilia ao investigador a ter uma melhor noção antecipada do conteúdo do *abstract*, facilitando para este saber se mesmo com a classificação concluída, este mesmo artigo realmente seria o que o investigador deseja, lembrando que o classificador supervisionado proposto nesta dissertação, não substitui o trabalho humano de fazer uma classificação mais completa e precisa.

Na Fig. 43, mostra o resultado da sumarização do *abstract* do artigo Doc nº 16474, este campo é o índice original que os revisores deram a cada artigo de um total de 530 contidos no *corpus* balanceado. Esta sumarização baseia-se no conteúdo analisado estatisticamente pelo modelo LDA com Mallet, sendo possível de ser realizada com ajuda da biblioteca *Gensim* utilizando a função do TextRank

Documento mais representativo para cada tópico - Abstract Sumarizado

Nº 1

Index: 296 Doc. Nº. 16474

Título:
Quality of life among Brazilian children with epilepsy: validation of a parent proxy instrument (QVCE-50).

Abstract:
PURPOSE: To analyze the validity and reliability of an epilepsy specific health related quality of life (HRQL) instrument (QVCE-50), constructed for Brazilians.
The QVCE-50 comprises the following domains: physical (9 items), psychological (18 items), social/familial (7 items), and cognitive/educational (16 items).
QVCE-50 was analyzed for internal consistency, reliability, content and concurrent validity.
RESULTS: Socio-demographic and clinical variables that differed in at least one domain were age, sex, time since diagnosis, epilepsy family history, and antiepileptic drug used.
Internal consistency, analyzed by Cronbach's alpha, showed good results for total and domain scores: physical (0.68), psychological (0.86), socio-familial (0.70) and cognitive-educational (0.81).

Figura 43 - Sumarização dos artigos, abrangendo os Abstract de cada documento.

Na Fig. 44 apresenta como era o conteúdo do *abstract* do mesmo artigo na lista antes da sumarização.

[16474,
1,
'Quality of life among Brazilian children with epilepsy: validation of a parent proxy instrument (QVCE-50).',
"PURPOSE: To analyze the validity and reliability of an epilepsy specific health related quality of life (HRQL) instrument (QVCE-50), constructed for Brazilians. The QVCE-50 comprises the following domains: physical (9 items), psychological (18 items), social/familial (7 items), and cognitive/educational (16 items). Items were scored on a four point scale. Domains were equally weighted using percent scores. The questionnaire ends with a quality of life scale scored 0-10 and a space for free observations. METHODS: A total of 77 children with epilepsy were consecutively seen in a neuropaediatric ambulatory unit. Parents or caregivers responded to the QVCE-50 and a Portuguese version of ICIS (Impact of Childhood Illness Scale). QVCE-50 was analyzed for internal consistency, reliability, content and concurrent validity. Clinical and socio-demographic variables were also analyzed. RESULTS: Socio-demographic and clinical variables that differed in at least one domain were age, sex, time since diagnosis, epilepsy family history, and antiepileptic drug used. Internal consistency, analyzed by Cronbach's alpha, showed good results for total and domain scores: physical (0.68), psychological (0.86), socio-familial (0.70) and cognitive-educational (0.91). Total scores on the QVCE-50 and ICIS are inversely correlated (Pearson's $r=-0.74$, $p<0.0001$). The Intraclass Correlation Coefficients for test-retest reliability were acceptable: physical (0.51), psychological (0.62), socio-familial (0.66), cognitive-educational (0.85) and total (0.77), $p<0.0001$. CONCLUSIONS: QVCE-50 has good psychometric properties. It is a useful tool for analyzing HRQL in children with epilepsy for Portuguese speakers, especially Brazilians. Other properties should be further tested, such as responsiveness to drug and surgical treatment, capacity of distinguishing among seizure control

Figura 44 - Conteúdo do artigo com índice 16474 antes da sumarização.

Junto com a sumarização, também é apresentado o reconhecimento das EN contidas no *abstract*, conforme foi mencionado e explicado na seção 3.7. Veja Fig. 45.

Reconhecimento de entidade do Abstract.

PURPOSE: To analyze the validity and reliability of an epilepsy specific health related quality of life (**HRQL PERSON**) instrument (QVCE-50), constructed for **Brazilians NORP** . The QVCE-50 comprises the following domains: physical (**9 CARDINAL** items), psychological (**18 CARDINAL** items), social/familial (**7 CARDINAL** items), and cognitive/educational (**16 CARDINAL** items). Items were scored on a **four CARDINAL** point scale. Domains were equally weighted using percent scores. The questionnaire ends with a quality of life scale scored **0 CARDINAL** -10 and a space for free observations. METHODS: A total of **77 CARDINAL** children with epilepsy were consecutively seen in a **neuropaediatric ambulatory ORG** unit. Parents or caregivers responded to the QVCE-50 and a **Portuguese NORP** version of **ICIS ORG** (Impact of Childhood Illness Scale). QVCE-50 was analyzed for internal consistency, reliability, content and concurrent validity. Clinical and socio-demographic variables were also analyzed. RESULTS: Socio-

Figura 45 - Reconhecimento de entidades na sumarização dos Abstracts.

5. Conclusão

Esta dissertação teve como motivação para o seu desenvolvimento, buscar uma solução que permita resolver ou pelo menos atenuar a dificuldade de se fazer o serviço de triagem manual de artigos utilizados com o método de RS. A estimativa existente sobre o número de horas utilizado para fazer a revisão é amparada em campos de título e *abstract*, podendo ter duração média de dias a vários meses, tomando em conta a quantidade de artigos a ser passado pela triagem [13, 21].

Para a elaboração do corpus utilizado nesta dissertação, foi colhido do motor de busca PubMed um conjunto com 17.132 artigos, deste total os revisores conseguiram fazer a triagem de 327 artigos, levando em média para poder classificar em “relevante” ou “não relevante” um único artigo cerca de 10 minutos. Para conclusão desta tarefa, os revisores gastaram um tempo de 54.5 horas para classificar 327 artigos, sendo que este *corpus* não se apresenta balanceado.

O classificador proposto para o apoio a RS na triagem de artigos, elaborado com método de *machine learning* em conjunto com técnicas de processamento de texto como *text mining* e NLP, é empregado no *corpus* com uma proporção de 4.27:1 ou seja, 265 artigos classificados como “não relevante” e 62 artigos classificados como “relevante” (veja Fig. 20). Para sanar esse problema de desequilíbrio, foi empregado a técnica de *oversampling* possibilitando que este mesmo *corpus* contenha um número de artigos “relevante” com uma maior proporção, colaborando para uma classificação mais precisa.

Com o *corpus* balanceado já com 530 artigos e processado pelo classificador proposto para o apoio a RS, obteve-se um total de 232 artigos classificados como relevantes, com uma precisão de 96.6%, uma acurácia de 81% ,F1Score de 56%, e a renovação de 63% contrário dos 216 artigos classificados como não relevantes, consumindo em média 10 minutos para obter a classificação com o *corpus* proposto e balanceado, mostrando uma margem de diferença de tempo em relação a triagem manual feito pelos investigadores.

Para fins de curiosidade em saber se mesmo com uma quantidade alta de artigos seria mais demorada para classificar, nesta mesma dissertação foi utilizado todo o *corpus* proposto contendo artigos classificados pelos revisores e os artigos que não puderam ser classificados com um total de 16.804, levando em conta que não foi medido a precisão da classificação e sim o tempo consumido. Deste conjunto de artigos classificados e não classificados somando 17.132 artigos, foi utilizando o mesmo algoritmo do classificador, este foi mais rápido do que a triagem manual, levando em média 45 minutos para concluir a classificação de todos os

artigos classificados e os não classificados, sendo que para a mesma equipa de revisores, este tempo poderia chegar a 118 dias ou 3 meses e 28 dias.

O classificador de aprendizagem automática para semi-automatizar o processo de classificação, pode ajudar tanto os investigadores da área médica como também profissionais de outras áreas do saber, como biomedicina, áreas jurídicas, história, áreas que demandam bastante investigações, oferecendo uma maior agilidade e precisão na hora do investigador e dos revisores obterem os artigos desejados, através da classificação utilizando os campos de título e *abstract*. Este tema mostra que a aprendizagem automática para apoio a RS, ajuda as pessoas nos seus serviços diários de investigações, semi-automatizando o processo de busca de informações de um modo mais rápido e prático, facilitando o acesso as literaturas através de classificadores desenvolvidos com os métodos de *machine learning*.

5.1. Trabalhos Futuros

Com trabalhos futuros pretende-se abordar os seguintes temas:

- Utilizar o algoritmo de sumarização de texto para reduzir o conteúdo dos artigos colhidos, ajudando os revisores a lerem as partes importantes de todo o artigo antes do processo de classificação, evitando desperdício de tempo. Com isso pretende-se obter uma melhor triagem manual antes de passar pela classificação supervisionada.
- Automatizar o processo de seleção de artigos nos motores de busca PubMed e MEDLINE com sumarização dos textos, como proposto no primeiro item desta seção, mas com uma diferença que esse processo de sumarização seria empregado no início do processo de seleção pelo *script* desenvolvido na dissertação presente.
- No processo de classificação, utilizar para treino artigos já sumarizados. Assim espera que estes retornem uma classificação melhor.
- Obter a classificação sem passar por aprendizagem supervisionada, podendo aproveitar não somente os artigos com classes definidas como aqueles que não tiveram oportunidade de serem classificados através da classificação supervisionada.

Ao final da triagem, os investigadores e os revisores poderão ficar menos preocupados com o tempo para fazer a classificação, utilizando da técnica de sumarização e classificação não supervisionada (não utilizada nesta dissertação), poupará tempo e custos financeiros no processo de triagem automática.

Bibliografia

- [1] Newton, I. - 1676. *"Letter from Sir Isaac Newton to Robert Hooke"*. Historical Society of Pennsylvania. Retrieved 22 March 2020.
- [2] Brocke, V. - *Et Al.*, 2009. *Reconstructing the giant: on the importance of rigour in documenting the literature search process*. Paper presented at the Proceedings of the 17th European Conference on Information Systems (ECIS 2009); Verona, Italy. 2009.
- [3] Paré G., Trudel M.- C., Jaana M., Kitsiou S. *Synthesizing information systems knowledge: A typology of literature reviews*. Information & Management. 2015;52(2):183–199.
- [4] Lau F., Kuziemsky C., editors. *Handbook of eHealth Evaluation: An Evidence-based Approach*. Victoria (BC): University of Victoria; 2016.
- [5] Levy Y., Ellis T.J. *A systems approach to conduct an effective literature review in support of information systems research*. Informing Science. 2006;9:181–211.
- [6] Green B. N., Johnson C. D., Adams A. *Writing narrative literature reviews for peer-reviewed journals: secrets of the trade*. Journal of Chiropractic Medicine. 2006;5(3):101–117. [PMC free article] [PubMed]
- [7] J. S. Brainard, N. Jones, I. Lake, L. Hooper, P. Hunter. 2020. *Facemasks and similar barriers to prevent respiratory illness such as COVID-19: A rapid systematic review*. medRxiv doi: <https://doi.org/10.1101/2020.04.01.20049528>
- [8] E. Mullins, D. Evans, R.M. Viner, P. O'Brien, E. Morris. 2020. *Coronavirus in pregnancy and delivery: rapid review and expert consensus*. medRxiv doi: <https://doi.org/10.1101/2020.03.06.20032144>
- [9] Gagnon MP. *Hospital-based health technology assessment: developments to date*. Pharmacoeconomics. 2014;32(9):819–24. doi:10.1007/s40273-014-0185-3.
- [10] L. Bornmann, R. Mutz. *Growth rates of modern science: A bibliometric analysis based on the number of publications and cited references*. J. Assoc. Inf. Sci. Technol., 2014.
- [11] Landhuis, E. *Scientific literature: Information overload*. Nature 535, 457–458 (2016). <https://doi.org/10.1038/nj7612-457a>
- [12] Tsertsvadze, A., Chen, Y., Moher, D. et al. *How to conduct systematic reviews more expeditiously?*. Syst Rev 4, 160 (2015). <https://doi.org/10.1186/s13643-015-0147-7>
- [13] R.M. Featherstone, D.M. Dryden, M. Foisy, J.M. Guise, M.D. Mitchell, R.A. Paynter, et al. *Advancing knowledge of rapid reviews: an analysis of results, conclusions and*

recommendations from published review articles examining rapid reviews. Syst Rev. 2015;4:50. doi:10.1186/s13643-015-0040-4.

[14] E. Mullins, D. Evans, R.M. Viner, P. O'Brien, E. Morris. 2020. *Coronavirus in pregnancy and delivery: rapid review and expert consensus.* medRxiv doi: <https://doi.org/10.1101/2020.03.06.20032144>

[15] Jonnalagadda S.R., Goyal P., Huffman M.D.. *Automating data extraction in systematic reviews: a systematic review.* Syst Rev. 2015;4:78.

[16.] O'Mara-Eves A, Thomas J., McNaught J., Miwa M., Ananiadou S. *Using text mining for study identification in systematic reviews: a systematic review of current approaches.* Syst Rev. 2015;4:5.

[17] I. J. Marshall, B. C. Wallace. *Toward systematic review automation: a practical guide to using machine learning tools in research synthesis.* Systematic Reviews (2019)8:163.

[18] Kitchenham B.A., Brereton P., Budgen D., Turner M., Bailey J., Linkman S. *Systematic literature reviews in software engineering – A systematic literature review.* Inf. Softw. Technol.. 2009;51(1):7–15.

[19] Silva, F.Q. da, Santos, A.L., Soares, S., Franca, A.C.C., Monteiro, C.V., Maciel, F.F. (2011) *Six years of systematic literature reviews in software engineering: an updated tertiary study.* Inf. Softw. Technol., v. 53, n. 9, p. 899-913.

[20] M. Makoto, J. Thomas, A. O'Mara-Eves, S. Ananiadou. 2013. *Reducing systematic review workload through certainty-based screening.* (2014), DOI: <https://doi.org/10.1016/j.jbi.2014.06.005>

[21] Felizardo, K.R; Nakagawa, E.Y; Ferraz Febbri, S.C.P; Ferrari, F. C – *Revisão Sistemática da literatura em engenharia de software, Teoria e Prática*, 1ª ed. Editora Elsevier, 2017. ISBN (versão digital): 978-85-352-8597-0

[22] Sackett D.L., Rosenberg W.M.C., Gray JAM, Haynes R.B., Richardson W.S.. *Evidence based medicine: what it is and what it isn't.* Br. Med. J..1996;1(316):71–72.

[23] Kitchenham, B.A. (2004) *Procedures for performing systematic reviews.* Joint Technical Report. Software Engineering Group Department of Computer Science Keele University, Keele, UK and Empirical Software Engineering National ICT Australia, Eversleigh, Austrália.

[24] Zhang H., Babar M.A.. *Systematic reviews in software engineering: An empirical investigation.* Inf. Softw. Technol.. 2013;55(7):1341–1354.

[25] Marshall C. *Systematic Review (SR) toolbox* 2015. <http://systematicreviewtools.com/>. Accessed 05 November 2015.

- [26] Balk E.M., Chung M., Chen M.L., Trikalinos T.A., Kong Win Chang L. *Assessing the accuracy of google translate to allow data extraction from trials published in non-english languages*. Rockville (MD). 2013. <http://effectivehealthcare.ahrq.gov/index.cfm/search-for-guides-reviews-and-reports/?productid=1386&pageaction=displayproduct>. Accessed on 5 November 2015.
- [27] Gartlehner, G., Wagner, G., Lux, L. et al. *Assessing the accuracy of machine-assisted abstract screening with DistillerAI: a user study*. Syst Rev **8**, 277 (2019). <https://doi.org/10.1186/s13643-019-1221-3>
- [28] Distiller S.R., Disponível em: <<https://www.evidencepartners.com/products/distillersr-systematic-review-software/>> [Acessado em 18/05/2020]
- [29] Lanera, C., Berchialla, P., Sharma, A. et al. *Screening PubMed abstracts: is class imbalance always a challenge to machine learning?*. Syst Rev **8**, 317 (2019). <https://doi.org/10.1186/s13643-019-1245-8>
- [30] Bannach-Brown, A., Przybyła, P., Thomas, J. et al. *Machine learning algorithms for systematic review: reducing workload in a preclinical review of animal studies and reducing human screening error*. Syst Rev **8**, 23 (2019). <https://doi.org/10.1186/s13643-019-0942-7>
- [31] Rezende, S. - *Sistemas Inteligentes: Fundamentos e Aplicações*, 1ª ed. Editora Manole Brasil, 2003. ISBN: 85-204-1683-7
- [32] Grus, J. - *Data Science do Zero, Primeiras Regras com Python*, 1ª ed. Editora Alta Books, 2016. ISBN 978-85-7608-998-8
- [33] Tsuruoka Y, Miwa M, Hamamoto K, Tsujii J, Ananiadou S. *Discovering and visualizing indirect associations between biomedical concepts*. Bioinformatics 2011;27(13): i111–9.
- [34] Ananiadou S, McNaught J. *Text mining for biology and biomedicine*. Boston/London: Artech House; 2006.
- [35] Sasaki Y, Rea B, Ananiadou S. *Clinical text classification under the open and closed topic assumptions*. Int J Data Mining Bioinform 2009;3(3):299–313.
- [36] Wallace B, Trikalinos T, Lau J, Brodley C, Schmid C. *Semi-automated screening of biomedical citations for systematic reviews*. BMC Bioinform 2010;11(1):55.
- [37] Cortes C., Vapnik V. *Support-vector networks*. Mach Learn 1995;20(3):273–97.
- [38] Géron, A. - *Mãos à Obra: Aprendizado de Máquina com Scikit-Learn & TensorFlow: Conceitos, Ferramentas e Técnicas para construção de Sistemas Inteligentes*, 1ª ed. Editora Alta Books, 2019. ISBN: 978-85-508-0381-4.

- [39] Blei, D. M.; NG, A. Y.; Jordan, M. I. Latent dirichlet allocation. J. Mach. Learn. Res., JMLR.org, v. 3, p. 993–1022, mar. 2003. ISSN 1532-4435. Disponível em: <<http://dl.acm.org/citation.cfm?id=944919.944937>>
- [40] Bannach-Brown, A., Przybyła, P., Thomas, J. et al. *Machine learning algorithms for systematic review: reducing workload in a preclinical review of animal studies and reducing human screening error*. Syst Rev 8, 23 (2019). <https://doi.org/10.1186/s13643-019-0942-7>
- [41] Cohen A.M., Adams C.E., Davis JM, Yu C, Yu PS, Meng W, et al. *Evidence-based medicine, the essential role of systematic reviews, and the need for automated text mining tools*. In: Proceedings of the 1st ACM international Health Informatics Symposium: ACM; 2010. p. 376–80.
- [42] S. Haykin. *Neural Networks - A Comprehensive Foundation*. 2^a Ed. New Jersey: Prentice-Hall, 1999.
- [43] PUBMED, Disponível em: <<https://www.ncbi.nlm.nih.gov/pubmed/>> [Acessado em 18/06/2019].
- [44] MEDLINEM, Disponível em: <<https://www.nlm.nih.gov/bsd/pmresources.html>> [Acessado em 18/06/2019].
- [45] Ros, R; Runeson, P; Bjarnason, E - *A Machine Learning Approach for Semi-Automated Search and Selection in Literature Studies*, n.Jun, p 118-127, 2017
- [46] M. Miwa, J. Ćomas, A. O'Mara-Eves, and S. Ananiadou. 2014. *Reducing Systematic Review Workload Ćrough Certainty-based Screening*. *Journal of Biomedical Informatics* 51 (2014), 242–253. DOI:[hŠp://dx.doi.org/10.1016/j.jbi.2014.06.005](https://doi.org/10.1016/j.jbi.2014.06.005)
- [47] Tan, A.-H. *Text Mining: The state of the art and the challenges*. In Proceedings of the pakdd, Workshop On Knowledge Disocvery From Advanced Databases. (1999).
- [48] C. Cortes and V. Vapnik. 1995. *Support-Vector Networks*. *Machine Learning* 20, 3 (1995), 273–297. DOI:<http://dx.doi.org/10.1007/BF00994018>
- [49] Thomas J, McNaught J, Ananiadou S. *Applications of text mining within systematic reviews*. Res Synth Methods 2011;2(1):1–14.
- [50] Wei, X., & Croft, W. B. (2006). *Lda-based document models for ad-hoc retrieval*. In Proceedings of the 29th annual international acm sigir conference on research and development in information retrieval.
- [51] Wallace B, Trikalinos T, Lau J, Brodley C, Schmid C. *Semi-automated screening of biomedical citations for systematic reviews*. BMC Bioinform 2010;11(1):55.

- [52] Lefebvre C, Manheimer E, Glanville J. *Cochrane handbook for systematic reviews of interventions*, version 5.1.0 edition, chap. 6; 2011.
- [53] Sarmiento, Luís. “*Medidas de Associação*”. Simpósio Doutoral Linguatca, 3, 4 Outubro 2006.
- [54] Bruce, P., BRUCE, Andrewv - *Estatística Prática para Cientista de Dados: 50 conceitos essenciais*. 1ª ed. Editora Alta Books, 2019. ISBN 978-85-508-0603-7
- [55] Hotho, A., A. Nürnberger, et al. (2005). "A brief survey of text mining." LDV Forum - GLDV Journal for Computational Linguistics and Language Technology.
- [56] Andrade, M. A. ,Helena, P. — *Aplicação de Técnicas de Mineração de Textos para Classificação de Documentos: um Estudo da Automatização da Triagem de Denúncias na CGU*. Brasília: Universidade de Brasília, 2015, Dissertação de Mestrado em Computação Aplicada.
- [57] Weiss, S., N. Indurkha, Zhang T., and Damerau, F. *Text Mining: Predictive Methods for Analyzing Unstructured Information*. Springer, 2004
- [58] Santos, C. M. - *Classificação de Documentos com Processamento de Linguagem Natural*. Coimbra: Instituto Superior de Engenharia de Coimbra, 2015. Dissertação de mestrado em Informática e Sistemas
- [59] A. O'Mara-Eves, , J. Tomas, J. McNaught, M. Miwa, and S. Ananiadou. 2015. *Using Text Mining for Study Identification in Systematic Reviews: A Systematic Review of Current Approaches*. Systematic Reviews 4, 1 (2015), 5. DOI: <http://dx.doi.org/10.1186/2046-4053-4-5>
- [60] Rodrigues, H. J. F. - *Ferramenta para Text Mining em Textos completos*. Porto: Universidade do Porto, 2016. Dissertação de mestrado em Engenharia Informática e Computação
- [61] Aranha, C. N.; Vellasco, M. *Uma abordagem de pré-processamento automático para Mineração de textos em português: sob o enfoque da inteligência computacional*. Pontifícia Universidade Católica do Rio de Janeiro, Rio de Janeiro, RJ, 2007
- [62] Indurkha, N.; Damerau, F. J. *Handbook of natural language processing*. [S.l.]: CRC Press, 2010.
- [63] Gomes, H. J. C. *Text mining: análise de sentimentos na classificação de notícias*. Instituto Superior de Estatística e Gestão de Informação. Universidade Nova de Lisboa. Portugal. 2012
- [64] Bird, S., Klein, E., Loper, E. - *Natural Language Processing with Python*. 1ª. Ed. Sebastopol: Editora O'Reilly Media, Inc, 2009. ISBN: 978-0-596-51649-9.

- [65] Manning, C. D. et al. *Introduction to information retrieval*. [S.l.]: Cambridge university press Cambridge, 2008.
- [66] Martins, C. A.; Monard, M.; Matsubara, E. T. - *Reducing the dimensionality of bag-of-words text representation used by learning algorithms*. In Proceedings of The Third IASTED International Conference on Artificial Intelligence and Applications (AIA 2003), Benalmádena, Espanha. (to be published), volume 38, 2003. 6
- [67] Wives, L. K.; Loh, S. *Recuperação de informações usando a expansão semântica e a lógica*.
- [68] Brito, E. M. N. D. *Mineração de textos: detecção automática de sentimentos em comentários nas mídias sociais*. Projetos e Dissertações em Sistemas de Informação e Gestão do Conhecimento, v. 6, n. 1, 2017
- [69] Bergmanis, B.; Goldwater, S - *Training Data Augmentation for Context-Sensitive Neural Lemmatization Using Inflection Tables and Raw Text*, n.Apr 2019.
- [70] Martin F. Porter. *An Algorithm for Suffix Stripping*. Program, 14(3):130–137, 1980. 26
- [71] Oguri, P.; Milidií, R. L.; Renteria, R. *Machine Learning for Sentiment Classification*. MsC Thesis — Department of Informática, Pontifícia Universidade Católica do Rio de Janeiro. Rio de Janeiro. 2006
- [72] Magalhães, B. N.. *“Avaliação de métodos não-supervisionados de seleção de atributos para Mineração de Textos”*. Fevereiro 2009.
- [73] Santos, B.. *“Níveis de processamento de texto”*. 2006
- [76] Alexandra I. M. Alves, *Modelo de representação de texto mais adequado à Classificação*. Porto: Instituto Superior de Engenharia do Porto, 2010. Dissertação para obtenção do Grau de Mestre em Engenharia Informática Área de especialização em Tecnologias do Conhecimento e Decisão.
- [77] Martins, C., Monard, M., E. Matsubara. *Uma Metodologia para Auxiliar na Seleção de Atributos Relevantes usados por Algoritmos de Aprendizado no Processo de Classificação de Textos*, 2007, Universidade de São Paulo.
- [78] TF-IDF, "term frequency-inverse document frequency". Disponível em: < <http://www.tfidf.com> > [Acesso em 16/06/2019].
- [79] Prabowo, R.; Thelwall, M. *Sentiment analysis: A combined approach*. Journal of Informetrics, Elsevier, v. 3, n. 2, p. 143–157, 2009.
- [80] Martins, J. *Classificação de páginas na internet*. Trabalho de Conclusão (Mestrado). Instituto de Ciências Matemáticas e de Computação. USP. São Carlos, 2003.

- [81] Tan, A.-H. (1999). *Text mining: The state of the art and the challenges*. In Proceedings of the pakdd 1999 workshop on knowledge discovery from advanced databases.
- [82] Martins, C. A. – *Uma abordagem para pré-processamento de dados textuais em algoritmo de aprendizado*. São Carlos: Universidade de São Paulo – USP, 2003. Tese de Doutorado em Ciências Matemática e de Computação.
- [83] SCIKIT-LEARN, "1.4 Support Vector Machines". Disponível em: <<http://scikit-learn.org/stable/modules/svm.html>> [Acesso em 16/06/2019].
- [84] LI, F.-F.; PERONA, P. *A bayesian hierarchical model for learning natural scene categories*. In: Proceedings of the 2005 IEEE Computer Society Conference on Computer Vision and Pattern Recognition (CVPR'05) - Volume 2 - Volume 02 . Washington, DC, USA: IEEE Computer Society, 2005. (CVPR '05), p. 524–531. ISBN 0-7695-2372-2. Disponível em: <<http://dx.doi.org/10.1109/CVPR.2005.16>>
- [85] Broniatowski, D. A.; Magee, C. L. *Analysis of social dynamics on fda panels using social networks extracted from meeting transcripts*. In: SocCom. [s.n.], 2010. Disponível em: <http://ieeexplore.ieee.org/xpls/abs_all.jsp?arnumber=5591237&tag=1>
- [86] Liu, B. *Sentiment analysis and opinion mining*. Synthesis Lectures on Human Language Technologies, Morgan & Claypool Publishers, v. 5, n. 1, p. 1–167, 2012.
- [87] Brito Nunes, E. M. - *Mineração de Textos: Detecção automática de sentimentos em comentários nas mídias sociais*. Belo Horizonte, Universidade Fundação Mineira de Educação e Cultura, 2017. Dissertação de Mestrado em Sistemas de Informação e Gestão do Conhecimento
- [88] Gonçalves, T. et al. *Analysing part-of-speech for portuguese text classification*. In: Computational Linguistics and Intelligent Text Processing. [S.l.]: Springer, 2006. p. 551–562.
- [89] Gibbon, Dafydd; Moore, Roger; Winski, Richard (1998). *Handbook of Standards and Resources for Spoken Language Systems: Spoken language characterisation*. Berlim: Walter de Gruyter. ISBN 9783110157345. Consultado em 1 de março de 2018
- [90] Bernardo N. B. Lima, Leandro Martins Cioletti, Marcelo de O. Terra Cunha, Gastão A. Braga; *Entropia: introdução à Teoria Matemática da (des)Informação*; Departamento de Matemática - UFMG.
- [91] Röder, M., A. Both, and Hinneburg, A.. *Exploring the Space of Topic Coherence Measures*. In Proceedings of WSDM, 2015
- [92] N. Aletras and M. Stevenson. *Evaluating topic coherence using distributional semantics*. In Proc. of the 10th Int. Conf. on Computational Semantics (IWCS'13), pages 13--22, 2013

- [93] Chen, C.; Liaw, A.; Breiman, L. *Using random forest to learn imbalanced data*. [S.l.], july 2004. Disponível em: xlf.lib.berkeley.edu/reports/SDTRWebData/accessPages/666.html.
- [94] Lento, G. C - *Random forest em dados desbalanceados: uma aplicação na modelagem de churn em seguro saúde*. Rio de Janeiro: Fundação Getúlio Vargas Escola De Matemática Aplicada, 2017. Dissertação para o título de Mestre Em Modelagem Matemática Da Informação.
- [95] Piri, S., Delen, D., and Liu, T. (2018). *A synthetic informative minority over-sampling (simo) algorithm leveraging support vector machine to enhance learning from imbalanced datasets*. *Decision Support Systems*, 106, 15–29
- [96] Lloret, E., & Palomar, M. *Text summarization in progress: A literature review*. *Artificial Intelligence Review*, 37(1), 1-41, 2012.
- [97] G. Carenini, R. Ng, and A. Pauls, “*Multi-document summarization of evaluative text*,” *Proceedings of the European Chapter of the Association for Computational Linguistics (EACL)*, pp. 305–312, 2006.
- [98] SUMARIZATION.SUMMARIZER – *TEXTRANK SUMMARISER* Disponível em: <<https://radimrehurek.com/gensim/summarization/summariser.html>>[Acessado em 31/11/2019]
- [99] Amaral, Daniela O. F. - *O Reconhecimento De Entidades Nomeadas Por Meio De Conditional Random Fields Para A Língua Portuguesa*. Pontifícia Universidade Católica Do Rio Grande Do Sul, Faculdade De Informática, 2013. Dissertação apresentada como requisito parcial à obtenção do grau de Mestre em Ciência da Computação. Disponível em:<<http://tede2.pucrs.br/tede2/handle/tede/5246>>
- [100] Dos Santos, Ângelo F. - *Sumarização Automática de Texto*. Covilhã: Universidade da Beira Interior, 2012. Dissertação para obtenção do Grau de Mestre em Engenharia Informática.
- [101] Ferreira, R., Cabral, L., Lins, R., Silva, G., Freitas, F., Cavalcanti, G., Favaro, L. *Assesing sentence scoring techniques for extrative text summarization*. *Expert Systems with Applications*, 5755-5764, 2013. Free Summarizer. Acesso em: 12 de Fevereiro de 2014, Disponível em: <http://freesummarizer.com/>, 2014
- [102] Barrera, A., & Verma, R. *Combining syntax and semantics for automatic extractive single-document summarization*. *Proceedings of the 13th international conference on computational linguistics and intelligent text processing*, 366-377, 2012.
- [103] Cormen, Thomas H.; Leiserson, Charles E.; Rivest, Ronald L.; Stein, Clifford (2001), “*Section 22.1: Representations of graphs*”, *Introduction to Algorithms* (Second ed.), MIT Press and McGraw-Hill, pp. 527–531, ISBN 0-262-03293-7.

- [104] Rada, M.; Tarau, P - *TextRank: Bringing Order into Texts*. Department of Computer Science University of North Texas. Detron – TX – U.S.A
- [105] Cruz,F.;Troyano, J.A.;Enríquez,F.; Ortega,F.J-*TextRank como motor de aprendizaje en tareas de etiquetado*.
Disponível em:< <https://dialnet.unirioja.es/servlet/articulo?codigo=2675325>>
- [106] Mckinney, Wes – *Python para Análise de Dados, Tratamento de Dados com Pandas, Numpy e Ipython*, 1ª ed. Editora Novatec, 2018, ISBN 978-85-7522-647-6
- [107] Y. Chen, Daniel – *Análise de Dados com Python e Pandas* 1ª ed. Editora Novatec, ISBN 2018, 978-85-7522-699-5
- [108] Rehurek, R.; Sojka, P. *Software Framework for Topic Modelling with Large Corpora*. In: Proceedings of the LREC 2010 Workshop on New Challenges for NLP Frameworks,Valletta, Malta. Anais... ELRA, 2010. p.45–50. <http://is.muni.cz/publication/884893/en>.
- [109] GENSIM. MODELS. LDA MULTICORE, Disponível em:
https://3981349775gh.circleartifacts.com/0/documentation/html/generated/gensim.models.lda_multicore.LdaMulticore.html[Acessado em 30/11/2019]
- [110] Ebeid, I.A.; Arango, J.M - *Mallet vs GenSim: Topic Modeling Evaluation Report*.
Mallet vs GenSim: Topic modeling for 20 news groups report. n.April 23, 2016
- [111] Machine Learning for Language Toolkit, Disponível em:< <http://mallet.cs.umass.edu/> >
[Acessado em 31/11/2019]
- [112] Li, W., & McCallum, A. (2006). *Pachinko allocation: DAG-structured mixture models of topic correlations*. In Proceedings of the 23rd international conference on Machine learning (pp. 577-584). ACM
- [113] Blei, D., Griffiths, T., Jordan, M., Tenenbaum, J. *Hierarchical topic models and the nested Chinese restaurant process*. In Advances in Neural Information Processing Systems 16, Cambridge, MA, MIT Press, 2004.
- [114] readthedocs.org, Disponível em: <https://readthedocs.org/projects/pyldavis/downloads/pdf/latest/>> [Acessado em 02/12/2019]
- [115] Borras S. and Di Ciaccio A.. *Measuring the prediction error a comparison of cross-validation, bootstrap and covariance penalty methods*. Computational Statistics and Data Analysis, Borra e Ciaccio(2010), 54:2976-2989.
- [116]SCIKIT-LEARN-DOCS,<https://scikit-learn.org/stable/_downloads/scikit-learn-docs.pdf> [Acesso em 20/06/2019].

- [117] SCIKIT-LEARN, "*C-Support Vector Classification*." Disponível em: <https://scikit-learn.org/stable/_downloads/scikit-learn-docs.pdf>[Acesso em 20/06/2019].
- [118] Kohavi(1995) Ron Kohavi. *Measuring the prediction error. a comparison of c. Computacional Statistics and Data Analysis*, 1:2976-2989.
- [119] H. Wu and R. Luk and K. Wong and K. Kwok. "*Interpreting TF-IDF term weights as making relevance decisions*". *ACM Transactions on Information Systems*, 26 (3). 2008.
- [120] Gartlehner, G., Wagner, G., Lux, L. et al. *Assessing the accuracy of machine-assisted abstract screening with DistillerAI: a user study*. *Syst Rev* **8**, 277 (2019). <https://doi.org/10.1186/s13643-019-1221-3>
- [122] Jurasfsky D, Martin J H., *Speech and Language Processing. An Introduction to Natural Language Processing, Computational Linguistics, and Speech Recognition*, Third Edition draft, 2018.
- [123] Lorena, A, C; De Carvalho, A,C,P,L,F - *Uma Introdução às Support Vector Machines*. Departamento de Ciência da Computação, Instituto de Ciências Matemáticas e de Computação, Universidade de São Paulo, Centro de Matemática, Computação e Cognição, Universidade Federal do ABC.
- [124] Boser, B. E.; Guyon, I. M.; Vapnik, V. N. *A Training Algorithm for Optimal Margin Classifiers*. In: ANNUAL WORKSHOP ON COMPUTACIONAL LEARNING, 5, 1992, Pittsburgh. ACM Press. Pittsburgh: Haussler D, jul 1992. p.144-152 .
- [125] Drucker, H.; Burges, C. J.; Kaufman, L.; Smola, A.; Vapnik, V. *Support vector regression machines. Advances in neural information processing systems*, Morgan Kaufmann Publishers, p. 155–161, 1997.
- [126] Saradhi, V., Kamik, H., Mitra, P. *A Decomposition Method for Support Vector Clustering*. In Proc. of the 2nd International Conference on Intelligent Sensing and Information Processing (ICISIP), p. 268-271, 2005.
- [127] C. Campbell. *An introduction to kernel methods*. In R. J. Howlett and L. C. Jain, editors, *Radial Basis Function Networks: Design and Applications*, pages 155–192, Berlin, 2000. Springer Verlag.
- [128] C.-C. Chang and C.-J. Lin. LIBSVM: a library for support vector machines. Disponível em: <<http://www.csie.ntu.edu.tw/~cjlin/libsvm/>>. Acessado em: 02/07/2020.
- [129] De Paula Faleiros, T; De Andrade Lopes, L: *Modelos Probabilísticos De Tópicos: Desvendando o Latent Dirichlet Allocation*, Relatórios Técnicos, Universidade De São Paulo, Instituto de Ciências Matemáticas e de Computação, São Carlos – SP, 2016

- [130] Lanckriet, G. R. G.; Cristianini, N.; Bartlett, P.; Ghaoui, L. E.; Jordan, M. I. (2004). *"Learning the kernel matrix with semidefinite programming"*. Journal of Machine Learning Research. 5: 27–72 [p. 29]
- [131] Gunn, S.. *Support vector machines for classification and regression*. Technical report, Image Speech & Intelligent Systems Group, University of Southampton, 1998.
- [132] Lorena, Ana Carolina; Carvalho, André C. P. L. F. de. *Uma Introdução às Support Vector Machines*. Revista de Informática Teórica e Aplicada (RITA) V.14, n.2, p.43-67, 2007.
- [133] Faceli, K.. et al. *Inteligência Artificial: uma abordagem de aprendizagem de máquina*.
- [134] Rio de Janeiro: LTC, 2011. ASANO, A. *Support vector machine and kernel method*. Pattern information processing (2004 Autumn Semester), Session 12, 2005.
- [135] Chamasemani, F. F.; Singh, Y. P.. *Multi-class Support VectorMachine (SVM) classifiers- An Application in Hypothyroid detection and Classification*.
In: Sixth International Conference on Bio-Inspired Computing: Theories and Applications, 2011.
- [136] Souto, Marcilio Carlos Pereira de. et al. *Técnicas de Aprendizado de Máquina para problemas de Biologia Molecular*, p 103–152. In: *Minicursos de Inteligência Artificial*, Jornada de Atualização Científica em Inteligência Artificial, XXIII Congresso da Sociedade Brasileira de Computação, 2003.
- [137] El-Naqa, I. et al. *A support vector machine approach for detection of microcalcifications*. IEEE Transactions on Medical Imaging, 2(12): 1562 - 1563, December 2002.
- [138] Albuquerque, Rafael W. de. *Monitoramento da cobertura do solo no entorno de hidrelétricas utilizando o classificador SVM (Support Vector Machines)*. 2012. 95 p. Dissertação (Mestrado em Engenharia de Transportes) – Escola Politécnica da Universidade de São Paulo. Departamento de Engenharia de Transportes. São Paulo, 2012.
- [139] Faceli, K.. et al. *Inteligência Artificial: uma abordagem de aprendizagem de máquina*. Rio de Janeiro: LTC, 2011
- [140] Araújo, Keven M.. Et al. *Utilização do Algoritmo de Máquina de vetores de suporte (SVM) para predição de dados climáticos*. Trabalho de Conclusão de Curso (Bacharel em Ciência da Computação) – Universidade Luterana de Palmas, 2015

Anexo

Script utilizado para fazer a recolha dos artigos oriundos do PubMed.

```
import pandas as pd
import numpy as np
import pickle
from Bio import Entrez, Medline

file_loc = "keywordsbulk.xls"
df = pd.read_excel(file_loc, na_values=['NA'], usecols = "A")
df=df.dropna()
alpha = df['Alpha'].tolist()

df = pd.read_excel(file_loc, na_values=['NA'], usecols = "B")
df=df.dropna()
beta = df['Beta'].tolist()

df = pd.read_excel(file_loc, na_values=['NA'], usecols = "C")
df=df.dropna()
gamma = df['Gamma'].tolist()

tripleterms = []
for i in alpha:
    for j in beta:
        for k in gamma:
            aterm = i.lower() + ' ' + j.lower() + ' ' + k.lower()
            tripleterms.append(aterm)

doubleterms = []
for i in alpha:
    for j in beta:
        aterm = i.lower() + ' ' + j.lower()
        doubleterms.append(aterm)

allterms = tripleterms + doubleterms

Entrez.email = "goncalovaladao@gmail.com"
allpmids = []

for ttt in allterms:
    handle = Entrez.esearch(db='pubmed',
                            sort='relevance',
                            retmax='20',
                            term=ttt,
                            usehistory="y")
```

```

pmids = Entrez.read(handle)['IdList']
allpmids.extend(pmids)

allpmids = list(set(allpmids))

out_handle = open("auxiliary.txt", "w")

allpmidsaux = ','.join(allpmids)
fetch_handle = Entrez.efetch(db='pubmed',
                             rettype='medline',
                             retmode='text',
                             id=allpmidsaux)
data = fetch_handle.read()
fetch_handle.close()
out_handle.write(data)
out_handle.close()

with open("auxiliary.txt") as auxilhandle:
    therecords = Medline.parse(auxilhandle)
    recordslst = list(therecords)

auxilhandle.close()

with open('papers.dat','wb') as filename:
    pickle.dump(recordslst, filename)

```

Liste palavras-chave utilizadas no *script* para poder ter acesso aos artigos vindos do PubMed.

Symtoms/Manifestations	AND PRO term	AND QoL Terms
Cardiomyopathy	Patient reported outcomes	Quality of Life
Pericardial effusion	Patient reported outcome measures	Health related quality of life
Hepatomegaly	Observer reported outcomes	HRQOL
Cirrhosis	Observer reported outcome measures	Disease specific quality of life
Liver fibrosis	Caregiver reported outcomes	Symptom specific quality of life
Steatosis	Caregiver reported outcomes measures	
Feeding problems	Patient centered outcomes	
Feeding difficulties	Patient centred outcomes	
Gastrostomy	Proxy reported outcomes	
G-tube	proxy reported outcome measures	
Enteral feeding		
Diarrhea		
Vomiting		
Renal cysts		
Nephrotic syndrome		
Tubulopathy		
Osteopenia		
Kyphosis		
Scoliosis		
Joint contractures		
Hypotonia		
Psychomotor retardation		
Ataxia		
Hyporeflexia		
Stroke-like episodes		
Seizures		
Epilepsy		
Cerebellar hypoplasia		
Peripheral neuropathy		
Hypothyroidism		

Hypogonadism		
Thrombosis		
Development delay		
infections		
intellectual disability		
sleep disturbances		
strabismus		
retinitis pigmentosa		
nystagmus		
blindness		
behavioural problems		
behavioral problems		
behaviour		
behavior		
autism		
mood swings		
hyperinsulinemic hypoglycemia		
functional disability		
physical disability		

Link do código e corpus utilizado na dissertação:

<https://github.com/michaelborges21/AUTOMATIC-LEARNING-TO-SUPPORT-SYSTEMATIC-LITERATURE-REVIEW>